BỘ GIÁO DỤC VÀ ĐÀO TẠO
TRƯỜNG ĐẠI HỌC MỞ THÀNH PHỐ HỒ CHÍ MINH



HUỲNH QUANG VŨ

PHÁT HIỆN BẤT THƯỜNG VIDEO BẰNG GIÁM SÁT YẾU SỬ DỤNG MẠNG NHẬN THỨC NGỮ NGHĨA KÉP TÍCH HỢP CĂN CHỈNH NGUYÊN MẪU

ĐỒ ÁN NGÀNH
NGÀNH KHOA HỌC MÁY TÍNH

TP. Hồ Chí Minh, 2026

BỘ GIÁO DỤC VÀ ĐÀO TẠO
TRƯỜNG ĐẠI HỌC MỞ THÀNH PHỐ HỒ CHÍ MINH



HUỲNH QUANG VŨ - 2351010247

"PHÁT HIỆN BẤT THƯỜNG VIDEO BẰNG GIÁM SÁT YẾU SỬ DỤNG MẠNG NHẬN THỨC NGỮ NGHĨA KÉP TÍCH HỢP CĂN CHỈNH NGUYÊN MẪU"

ĐỒ ÁN NGÀNH
NGÀNH KHOA HỌC MÁY TÍNH

Giảng viên hướng dẫn:
TS. LÊ VIẾT TUẤN

TP. Hồ Chí Minh, 2026

Ý kiến cho phép bảo vệ Đồ án ngành của Giảng viên hướng dẫn

Giảng viên hướng dẫn: TS. Lê Viết Tuấn
Sinh viên thực hiện: Huỳnh Quang Vũ ...

Lời cảm ơn

Lời đầu tiên, em xin gửi lời cảm ơn chân thành sâu sắc nhất đến thầy TS. Lê Viết Tuấn, người đã luôn tận tình hướng dẫn và động viên em trong suốt quá trình thực hiện đồ án ngành này. Ngoài ra, em cũng xin gửi lời cảm ơn đến quý thầy cô khoa Công nghệ thông tin của Trường Đại học Mở TP.HCM, những người đã truyền đạt cho em nền tảng kiến thức vững chắc trong suốt thời gian học tập tại trường, giúp em có đủ tự tin để hoàn thành đồ án ngành này. Từ những lý do trên, em nhận thức sâu sắc rằng kết quả của đồ án này không chỉ là sự nỗ lực của riêng cá nhân em, mà còn là sự kết tinh từ sự giúp đỡ to lớn của tất cả mọi người. Tóm lại, em xin gửi đến mọi người lời chúc sức khỏe và thành công nhất. Trong quá trình thực hiện nghiên cứu sẽ khó tránh khỏi thiếu sót. Vì vậy, em rất mong nhận được góp ý từ quý Thầy, Cô để có thể cải thiện thêm để đề tài ngày càng hoàn thiện.

Mục lục

Ý kiến Giảng viên hướng dẫn **i**

Lời cảm ơn **ii**

Mục lục **iii**

Danh mục từ viết tắt **vii**

Tóm tắt **viii**

1 Mở đầu **1**

1.1 Tổng quan bài toán . . . 1

1.1.1 Phát hiện bất thường trong video (VAD) . . . 1

1.1.2 Cách tiếp cận dưới sự giám sát yếu (WS-VAD) . . . 1

1.2 Hạn chế của các phương pháp hiện tại . . . 2

1.3 Mục tiêu và phạm vi đề tài . . . 2

1.3.1 Các mục tiêu cụ thể . . . 2

1.3.2 Phạm vi đề tài . . . 2

1.4 Phương pháp đề xuất . . . 3

1.5 Đóng góp của đề tài . . . 3

2 Cơ sở lý thuyết và Các nghiên cứu liên quan **4**

2.1 Cơ sở lý thuyết . . . 4

2.1.1 Bài toán phát hiện bất thường trong video (VAD) . . . 4

2.1.2 Mô hình CLIP . . . 4

2.1.3 Mạng tích chập đồ thị (GCN) . . . 5

2.1.4 Cơ chế Attention và Transformer . . . 6

2.1.5 Thuật toán phân ngưỡng động Otsu . . . 6

2.1.6 Cơ chế chọn mẫu Top-K . . . 7

2.1.7 Học chuyển giao (Transfer Learning) và kỹ thuật đóng băng trọng số (Weight Freezing) . . . 8

2.1.8 Kiến trúc mạng cơ sở DSANet (Baseline) . . . 9

2.2 Các công trình nghiên cứu liên quan . . . 10

2.2.1 Các phương pháp MIL và mô hình hóa thời gian . . . 10

2.2.2 Các phương pháp ứng dụng mô hình ngôn ngữ - thị giác . . . 10

2.2.3 Đánh giá tổng quan và so sánh . . . 11

3 Phương pháp đề xuất RUPA-DSA **12**

3.1 Tổng quan kiến trúc RUPA-DSA . . . 12

3.2 Mô-đun RUPA và Cổng định tuyến an toàn (Safe Gate) . . . 14

3.2.1 Cơ chế tái tạo đặc trưng của RUPA . . . 14
3.2.2 Cổng định tuyến an toàn (Safe Gate) . . . 14
3.3 Phân tích giới hạn của thiết kế Otsu và huấn luyện End-to-End . . . 15
3.3.1 Lý thuyết cơ chế hoạt động của phiên bản Otsu . . . 15
3.3.2 Sự sụp đổ đạo hàm (Gradient Collapse) trong thực tế . . . 16
3.4 Chiến lược khắc phục với Warm-Start và cơ chế Top-K . . . 16
3.4.1 Khắc phục nhiễu với chiến lược đóng băng Warm-Start . . . 17
3.4.2 Sự chuyển mình của Top-K: Từ rập khuôn thành Hard Negative Mining . . . 17
3.5 Hệ thống hàm mất mát (Loss Functions) . . . 17

4 Kết quả thử nghiệm **20**
4.1 Môi trường thử nghiệm . . . 20
4.2 Bộ dữ liệu . . . 20
4.2.1 Bộ dữ liệu UCF-Crime . . . 20
4.2.2 Bộ dữ liệu XD-Violence . . . 20
4.3 Độ đo đánh giá . . . 21
4.4 Kết quả trên phiên bản huấn luyện End-to-End . . . 21
4.5 Kết quả trên phiên bản huấn luyện Warm-Start . . . 22
4.5.1 Kết quả trên tập XD-Violence . . . 22
4.5.2 Kết quả trên tập UCF-Crime . . . 22
4.5.3 So sánh phiên bản huấn luyện End-to-End và Warm-Start . . . 23
4.5.4 Phân tích siêu tham số cho Safe Gate . . . 23
4.6 Đánh giá đóng góp của từng module . . . 24
4.6.1 Phân tích sự chênh lệch hiệu năng giữa các tập dữ liệu . . . 24
4.7 Trực quan hóa kết quả (Qualitative Results) . . . 25
4.8 Thảo luận . . . 25

5 Kết luận và Hướng phát triển **26**
5.1 Kết luận tổng quan . . . 26
5.2 Ưu điểm của phương pháp . . . 26
5.3 Hạn chế của nghiên cứu . . . 26
5.4 Khả năng ứng dụng thực tiễn . . . 27
5.5 Định hướng phát triển . . . 27
5.6 Lời kết . . . 27

Tài liệu tham khảo **28**

Danh sách hình

1.1 Khung hình bình thường với điểm dự đoán thấp (Nguồn: [1]). 1
1.2 Khung hình bất thường với điểm tăng cao (Nguồn: [1]). 1

2.1 Sơ đồ kiến trúc tổng thể của mô hình CLIP (Nguồn: [3]) 5
2.2 Cơ chế Scaled Dot-Product Attention (Nguồn: [5]) 6
2.3 Minh họa Otsu phân phối hai đỉnh (bimodal) của dữ liệu (Nguồn: [7] 7
2.4 Sơ đồ kiến trúc 3 nhánh của mạng cơ sở DSANet (Nguồn: [8]) 9

3.1 Sơ đồ kiến trúc tổng thể phiên bản RUPA-DSA 12
3.2 Sơ đồ kiến trúc phiên bản RUPA-DSA sử dụng phân ngưỡng tự động Otsu 16

4.1 Phân tích hiệu suất qua 10 Epoch minh họa hiện tượng Gradient Collapse khi huấn luyện End-to-End 22
4.2 Trực quan hóa điểm số bất thường do mô hình dự đoán theo từng khung hình 25

Danh sách bảng

2.1 So sánh đặc tính của các công trình nghiên cứu liên quan 11

3.1 Tóm tắt siêu tham số mặc định của hệ thống hàm mất mát 19

4.1 Cấu hình siêu tham số trên hai bộ dữ liệu 20
4.2 Thống kê tổng quan hai bộ dữ liệu 21
4.3 So sánh hiệu suất trên bộ dữ liệu XD-Violence 23
4.4 So sánh hiệu suất trên bộ dữ liệu UCF-Crime 23
4.5 Kết quả Ablation Study trên UCF-Crime và XD-Violence 24

Danh mục từ viết tắt

Từ viết tắt	**Cụm từ đầy đủ / Ý nghĩa**
VAD	Video Anomaly Detection (Phát hiện bất thường trong video)
WS-VAD	Weakly-Supervised VAD (Phát hiện bất thường dưới sự giám sát yếu)
RUPA	Reliability-Aware Unified Prototype Alignment (Căn chỉnh nguyên mẫu thống nhất dựa trên độ tin cậy)
DSA(Net)	Dual Semantic-Aware (Network) (Mạng nhận thức ngữ nghĩa kép)
MIL	Multiple Instance Learning (Học đa thực thể)
CLIP	Contrastive Language-Image Pre-training (Mô hình ngôn ngữ - thị giác)
GCN	Graph Convolutional Network (Mạng tích chập đồ thị)
DNP	Dynamic Normal Patterns (Nguyên mẫu bình thường động)
AUC	Area Under the ROC Curve (Diện tích dưới đường cong ROC)
AP	Average Precision (Độ chính xác trung bình)
SOTA	State-of-the-Art (Trạng thái tiên tiến nhất)

Tóm tắt

Bài toán phát hiện bất thường trong video dưới sự giám sát yếu (WS-VAD) đang thu hút nhiều sự quan tâm từ cộng đồng nghiên cứu nhằm giảm thiểu chi phí gán nhãn thủ công đắt đỏ trên từng khung hình. Đồ án này tập trung nghiên cứu và cải tiến mạng cơ sở DSANet thành kiến trúc Mạng nhận thức ngữ nghĩa kép tích hợp căn chỉnh nguyên mẫu (sau đây gọi tắt là RUPA-DSA), thông qua việc tích hợp các mô-đun tinh chỉnh và chiến lược huấn luyện tối ưu nhằm khắc phục tình trạng nhiễu nhãn và xung đột đạo hàm.

Cụ thể, đề tài đã ứng dụng và khảo sát các kỹ thuật sau để giải quyết nhược điểm của mạng gốc:

- Chiến lược huấn luyện tịnh tiến (Warm-Start): Bằng cách đóng băng hoàn toàn mạng cơ sở và chỉ mở khóa nhánh tinh chỉnh RUPA, phương pháp này giúp chặn đứng các gradient nhiễu, tạo ra khả năng chống lại hiện tượng quên ngữ cảnh và bảo toàn nguyên vẹn không gian đặc trưng chất lượng cao đã học trước đó.

- Khảo sát so sánh Otsu và Top-k: Đồ án tiến hành thử nghiệm thuật toán phân ngưỡng động Otsu thay cho cơ chế chọn mẫu cứng nhắc. Tuy nhiên, dữ liệu cho thấy rằng cấu hình Top-k khi kết hợp với mạng nền DSANet đóng băng lại tạo ra kỹ thuật khai thác mẫu khó (Hard Negative Mining), mang đến sự ổn định và độ chính xác vượt trội nhất trong môi trường dữ liệu biến động.

- Tích hợp cơ chế Safe Gate: Đóng vai trò như bộ điều phối ở giai đoạn cuối, cổng định tuyến này tự động đánh giá, loại bỏ dự đoán sai lệch và kết hợp các luồng điểm số để đảm bảo kết quả đầu ra mượt mà, an toàn nhất.

Thực nghiệm cho thấy, với cấu hình vận hành tối ưu nhất (Top-k kết hợp warm-start), kiến trúc RUPA-DSA đã đạt được hiệu suất tiên tiến mới (SOTA). Cụ thể, mô hình đạt chỉ số AUC 89.55% (kèm AP 40.21%) trên bộ dữ liệu UCF-Crime và AP 87.04% trên bộ dữ liệu XD-Violence. Kết quả này vượt trội hoàn toàn so với phiên bản DSANet gốc, minh chứng cho thấy tính thực tiễn trong thực tế của đồ án và khả năng huấn luyện tốt trước các tập dữ liệu nhiễu.

Chương 1

Mở đầu

1.1 Tổng quan bài toán

1.1.1 Phát hiện bất thường trong video (VAD)

Trong bối cảnh thực trạng hiện tại, việc giám sát an ninh thông qua mạng lưới camera đang ngày càng trở nên phổ biến và liên tục thu thập một khối lượng dữ liệu video khổng lồ mỗi ngày. Theo các báo cáo thống kê quy mô toàn cầu, ước tính hiện nay đã có hơn 1 tỷ camera giám sát (CCTV) được lắp đặt trên toàn thế giới, mỗi ngày tạo ra hàng chục petabyte dữ liệu hình ảnh. Trước lượng thông tin lớn này, việc dựa vào con người để quan sát và phát hiện các sự cố bất thường theo thời gian thực là điều dường như bất khả thi. Do đó, bài toán phát hiện bất thường trong video (VAD) được phát triển nhằm cung cấp các giải pháp phân tích hình ảnh video hoàn toàn tự động. Mục đích của bài toán này là nhận diện nhanh chóng các hành vi hoặc sự kiện bất thường không tuân theo quy luật thông thường, ví dụ như tai nạn giao thông, bạo lực, hoặc trộm cắp,... Việc giải quyết tốt bài toán VAD đóng vai trò quan trọng trong việc xây dựng các hệ thống an ninh thông minh, giúp giảm thiểu nguồn nhân lực thủ công, rủi ro và phản ứng kịp thời với các tình huống nguy hiểm.



Hình 1.1: Khung hình bình thường với điểm dự đoán thấp (Nguồn: [1]).



Hình 1.2: Khung hình bất thường với điểm tăng cao (Nguồn: [1]).

1.1.2 Cách tiếp cận dưới sự giám sát yếu (WS-VAD)

Mặc dù bài toán VAD rất hữu ích, nhưng các phương pháp học có giám sát truyền thống lại vấp phải một rào cản cực kỳ lớn về chi phí xử lý dữ liệu. Cụ thể, người ta phải đánh dấu thủ công từng khung hình xem nó là bình thường hay bất thường, việc này tốn rất nhiều thời gian và nhân lực. Để khắc phục điểm yếu này, các nghiên cứu gần đây đã chuyển hướng sang thử nghiệm bài toán dưới sự giám sát yếu (Weakly-Supervised VAD). Tức là, thay vì gán nhãn từng khung hình là bình thường hay bất thường, WS-VAD chỉ yêu cầu gán nhãn ở mức độ video, tức là gán nhãn video đó có bất thường hay không. Từ đó, hệ thống chỉ cần biết video đó có chứa sự kiện bất thường hay không. Phương pháp này thường vận hành dựa trên cơ chế học đa thực thể (Multiple Instance Learning), giúp giảm thiểu đáng kể chi phí gán nhãn thủ công, đồng thời tăng khả năng có thể triển khai vào

thực tế đối với những tập dữ liệu quy mô lớn mà con người gần như không thể kiểm tra hết.

1.2 Hạn chế của các phương pháp hiện tại

Tuy nhiên, việc học trong môi trường giám sát yếu phải đối mặt với thách thức lớn về nhiễu nhãn giả, xảy ra khi các khung hình bình thường trong video bất thường bị hiểu sai thành bất thường. Các kiến trúc mới nổi bật gần đây như DSANet dù mang lại hiệu quả cao, nhưng vẫn áp dụng cơ chế lấy mẫu data normal và abnormal bằng top-k cố định dẫn đến việc quá rập khuôn và gây ra hiện tượng nhãn nhiễu khi gặp các video có thời lượng bất thường quá dài hoặc quá ngắn. Hạn chế gặp phải khi cố gắng ghép thêm các nhánh và hàm loss tinh chỉnh để khắc phục nhược điểm này, quá trình huấn luyện mở khóa toàn bộ mạng (end to end) sẽ khiến các luồng gradient nhiễu truyền ngược gây ảnh hưởng đến tổng trọng số của mô hình. Điều này gây ra hiện tượng quên ngữ cảnh từ đó ép không gian đặc trưng quá mức và phá hỏng toàn bộ những trọng số chất lượng cao mà mạng cơ sở DSANet đã học từ trước.

1.3 Mục tiêu và phạm vi đề tài

1.3.1 Các mục tiêu cụ thể

Để giải quyết triệt để những bài toán đã đặt ra, đồ án hướng tới các mục tiêu cụ thể sau:

- Tìm hiểu và phân tích điểm nghẽn gây ra nhiễu nhãn của cơ chế top-k trong mạng DSANet.
- Khảo sát và so sánh thuật toán phân ngưỡng động Otsu nhằm tìm ra phương án tối ưu thay thế cho cơ chế chọn mẫu rập khuôn.
- Khắc phục hiện tượng quên ngữ cảnh thông qua việc đề xuất chiến lược huấn luyện tịnh tiến 2 giai đoạn (Warm-Start).
- Xây dựng mô-đun tinh chỉnh RUPA kết hợp với cổng định tuyến an toàn (Safe Gate) để tạo thành Mạng nhận thức ngữ nghĩa kép tích hợp căn chỉnh nguyên mẫu (sau đây gọi tắt là kiến trúc RUPA-DSA).

1.3.2 Phạm vi đề tài

- **Đối tượng nghiên cứu:** Bài toán phát hiện bất thường trong video, đặc biệt tập trung vào hướng tiếp cận học dưới sự giám sát yếu (WS-VAD).
- **Giới hạn thuật toán:** Đồ án không thiết kế một bộ trích xuất đặc trưng mới từ đầu, mà tái sử dụng và bảo toàn không gian đặc trưng được trích xuất sẵn từ mô hình CLIP (ViT-B/16) và mạng cơ sở DSANet.
- **Giới hạn dữ liệu:** Tiến hành chạy thực nghiệm, đánh giá và so sánh hiệu năng trên hai bộ dữ liệu thực tế lớn là UCF-Crime và XD-Violence.

1.4 Phương pháp đề xuất

Để giải quyết triệt để những vấn đề khó khăn trên, em quyết định đề xuất một giải pháp cải tiến kiến trúc DSANet bằng cách tích hợp thêm mô-đun Căn chỉnh nguyên mẫu thống nhất dựa trên độ tin cậy (RUPA). Ban đầu, phương pháp này thử nghiệm thuật toán phân ngưỡng động Otsu nhằm chắt lọc khung hình sạch thay vì dùng cơ chế top-k rập khuôn. Quan trọng nhất, để chặn đứng hiện tượng quên ngữ cảnh, em áp dụng chiến lược huấn luyện 2 giai đoạn (warm-start) bằng cách đóng băng hoàn toàn mạng cơ sở DSANet tức cho main-lr = 0.0 và chỉ mở khóa học tập cho nhánh RUPA cho refiner-lr = 1e-5, mạng nền DSANet sẽ giúp mô hình chặn đứng mọi gradient nhiễu. Cuối cùng, một cổng định tuyến an toàn (safe gate) được thiết kế để kết hợp các luồng dự đoán một cách mượt mà.

1.5 Đóng góp của đề tài

Đồ án này hướng đến việc tối ưu hóa hiệu suất của hệ thống nhận diện thông qua các cải tiến kỹ thuật cụ thể, bao gồm những đóng góp chính sau đây:

- Nghiên cứu và mở rộng kiến trúc DSANet thông qua việc cắm ghép nhánh RUPA, giúp hệ thống vắt kiệt thông tin từ những đặc trưng bất thường tinh vi mà mạng cơ sở bỏ sót.
- Áp dụng thành công chiến lược huấn luyện tịnh tiến (warm-start). Đây là cốt lõi tạo ra khả năng chống lại hiện tượng quên ngữ cảnh, bảo toàn nguyên vẹn 100% không gian đặc trưng trích xuất từ CLIP và GCN.
- Khảo sát so sánh cơ chế phân ngưỡng Otsu và Top-k. Qua đó phát hiện ra dù Otsu giúp mô hình hội tụ an toàn nhờ cắt được các segment normal và abnormal chuẩn chỉnh, nhưng khi kết hợp Top-k với mạng nền bị đóng băng, các nhãn nhiễu vô tình biến thành kỹ thuật khai thác mẫu khó (Hard Negative Mining), tạo áp lực cho nhánh RUPA học được các mẫu khó đoán nhất. Từ đó cho thấy Top-k vẫn vượt trội trong ngữ cảnh RUPA-DSA.
- Thông qua 4 kịch bản nghiên cứu cắt bỏ (Ablation Study), đồ án đã tìm ra cấu hình vận hành tối ưu nhất (Top-K kết hợp Warm-Start). Cấu hình này giúp hệ thống tạo ra các đỉnh SOTA mới trên hai tập dữ liệu thực tế lớn: UCF-Crime (AUC 89.55%, AP 40.21%) và XD-Violence (AP 87.04%), vượt trội hoàn toàn so với hiệu năng của kiến trúc bản gốc.

Từ những đóng góp cải tiến trên, em tin rằng hướng đi này là một lựa chọn quan trọng để góp phần nâng cao độ chính xác cho các hệ thống an ninh hiện đại trong môi trường phức tạp và giảm thiểu báo động giả.

Chương 2

Cơ sở lý thuyết và Các nghiên cứu liên quan

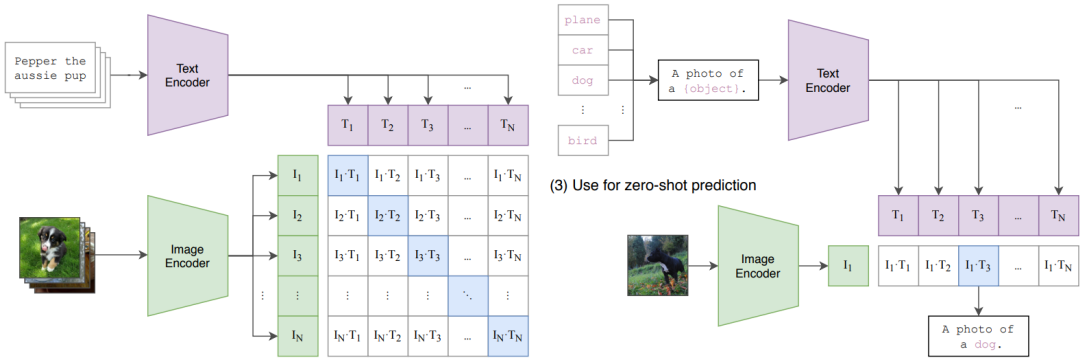
2.1 Cơ sở lý thuyết

2.1.1 Bài toán phát hiện bất thường trong video (VAD)

Phát hiện bất thường trong video là quá trình phân tích và xác định những hành vi, sự kiện không tuân theo các quy luật ban đầu hoặc các hành vi thông thường đã được định nghĩa bình thường. Các phương pháp VAD có thể được phân loại thành ba hướng chính gồm có học có giám sát (Supervised), học không giám sát (Unsupervised) và học giám sát yếu (Weakly-Supervised). Bài toán WS-VAD (Weakly-Supervised VAD) chủ yếu dựa trên kỹ thuật Multiple Instance Learning (MIL) [2], trong đó mỗi video được xem là một túi (bag) chứa nhiều đoạn nhỏ (instance), và mô hình phải dự đoán nhãn cho từng instance dựa trên nhãn bất thường hay bình thường của cả video. Tuy nhiên, một trong những rào cản lớn nhất của hướng tiếp cận này là nhãn bị nhiễu (Label Noise), xảy ra khi các đoạn video bình thường nằm ở trong một video bất thường bị đánh nhầm là bình thường. Từ đó, làm sai lệch hàm mất mát. Qua đó có thể thấy bài toán phức tạp này đòi hỏi sự kết hợp linh hoạt giữa các kỹ thuật xử lý hình ảnh và học máy để mang lại hiệu quả cao nhất.

2.1.2 Mô hình CLIP

Được giới thiệu bởi OpenAI, CLIP (Contrastive Language-Image Pre-training) [3]. Khác với các mạng phân loại truyền thống chỉ học trên các nhãn số cứng nhắc, CLIP được huấn luyện trực tiếp trên một tập dữ liệu quy mô rất lớn gồm khoảng 400 triệu cặp hình ảnh và đoạn văn bản mô tả thu thập từ internet. Về mặt kiến trúc, hệ thống này được cấu tạo từ hai luồng chính: một bộ mã hóa hình ảnh (Vision Transformer) ViT-B/16 và một bộ mã hóa văn bản (Text Transformer). Chức năng của hai bộ mã hóa này là biến đổi cả khung hình video và câu chữ thành các vector đặc trưng (thường là 256 hoặc 512 chiều) rồi đẩy nó vào cùng một không gian chung. Quá trình huấn luyện của CLIP dựa trên cơ chế học đối chiếu (Contrastive Learning). Tức là mô hình sẽ cố gắng tính toán độ tương đồng (cosine similarity) sao cho khoảng cách giữa vector ảnh và vector văn bản ghép cặp với nó càng gần nhau càng tốt, đồng thời đẩy các cặp ảnh và text không liên quan ra xa nhau. Nhờ vào việc ép buộc hai luồng image và text đồng bộ, CLIP có khả năng hiểu được ngữ nghĩa hình ảnh rất chính xác. Lý do chính khiến em và cũng như các nghiên cứu WS-VAD hiện nay tận dụng CLIP là nhờ khả năng suy luận không cần mẫu(zero-shot) hiệu quả của nó. Trong môi trường giám sát yếu, việc thiếu thốn nhãn chi tiết luôn là một bài toán khó. Tuy nhiên, bằng cách trích xuất đặc trưng qua CLIP, ta có thể đưa vào những câu prompt văn bản đơn giản như "Normal video" hay "Abnormal video". Từ đó, mô hình sẽ tự động đối chiếu để chấm điểm bất thường cho từng frame. Việc này giúp tận dụng sẵn những tri thức mạng đã học, qua đó không cần phải tốn tài nguyên huấn luyện lại từ đầu trên các tập dữ liệu mới. Đồng thời cải thiện độ chính xác khi đối mặt với các tình huống rất phức tạp ngoài thực tế.



Hình 2.1: Sơ đồ kiến trúc tổng thể của mô hình CLIP (Nguồn: [3])

2.1.3 Mạng tích chập đồ thị (GCN)

Mạng tích chập đồ thị (GCN) [4] là một loại kiến trúc mạng nơ-ron được thiết kế chuyên biệt để hoạt động trên các cấu trúc dữ liệu đồ thị, giúp trích xuất các mối quan hệ phức tạp giữa các điểm nút (nodes). Công thức cập nhật trạng thái cơ bản của GCN cho tầng thứ $l+1$ có thể được biểu diễn như sau:

$$H^{(l+1)} = \sigma\left(\tilde{D}^{-\frac{1}{2}}\tilde{A}\tilde{D}^{-\frac{1}{2}}H^{(l)}W^{(l)}\right) \tag{2.1}$$

Trong đó:

- H là ma trận đặc trưng chứa các vector trích xuất từ CLIP.
- $\tilde{A}$ là ma trận kề có thêm các liên kết tự lặp. Từ đó xác định mức độ liên kết giữa các đoạn video.
- $\tilde{D}^{-\frac{1}{2}}$ là ma trận bậc để chuẩn hóa, giúp cân bằng thông tin thu nhận và tránh trường hợp bùng nổ giá trị khi cộng dồn đặc trưng từ các ma trận kề. Hiểu một cách trực giác, nếu một đoạn video (node) có quá nhiều liên kết đến các đoạn khác, việc cộng dồn trực tiếp sẽ làm giá trị đặc trưng của nó phình to và lấn át các đoạn ít liên kết. Việc nhân hai phía với $\tilde{D}^{-\frac{1}{2}}$ đóng vai trò như một cơ chế chuẩn hóa đối xứng (symmetric normalization). Cơ chế này phân bổ đều tầm ảnh hưởng của mỗi node dựa trên bậc của nó, đảm bảo các khung hình dù có mật độ liên kết dày đặc hay thưa thớt đều đóng góp tín hiệu một cách cân bằng, ổn định vào mạng lưới.
- W là trọng số mạng cần huấn luyện.

Việc ứng dụng GCN giúp mô hình hiểu sâu hơn về cấu trúc ngữ cảnh của đoạn video. Đặc biệt trong kiến trúc DSANet, mô hình sử dụng cấu trúc Mạng tích chập đồ thị kép (Dual GCN) để thực hiện việc gom nhóm thông tin theo hai hướng đồng thời:

- Một đồ thị khoảng cách (Distance Graph): giúp liên kết các segment video gần nhau ở các mốc thời gian nhằm cho mô hình nắm bắt hành động diễn ra liên tục.

- Một đồ thị tương đồng (Similarity Graph): giúp liên kết các segment video có cùng ngữ cảnh đặc trưng hình ảnh cho dù chúng xảy ra cách xa nhau.

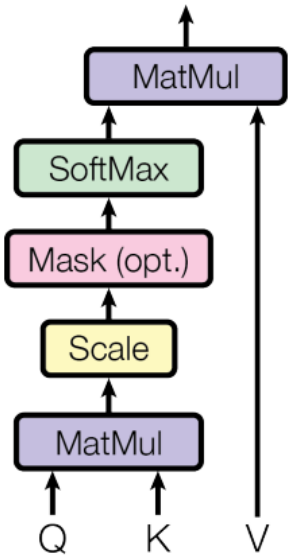
Việc ứng dụng linh hoạt GCN kép theo cách này giúp mô hình không bị mất dấu sự kiện và hiểu sâu hơn về ngữ cảnh của các segment video, qua đó cho thấy tiềm năng to lớn trong việc giải quyết dữ liệu thời gian.

2.1.4 Cơ chế Attention và Transformer

Cơ chế Self-Attention [5] là thành phần cốt lõi của mạng Transformer. Điểm mạnh của nó là khả năng tính toán trọng số chú ý cho tất cả các phần tử đầu vào song song. Bản chất của thuật toán này dựa trên ba ma trận chính gồm Query (Q), Key (K) và Value (V), được biểu diễn qua công thức sau:

$$Attention(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V \tag{2.2}$$

Trong đó: d_k là chiều dài của các véc-tơ đặc trưng. Việc nhân ma trận Q với K^T giúp hệ thống tự động tìm ra mức độ liên quan giữa các segment video với nhau. Thay vì xử lý tuần tự như các mạng RNN truyền thống, cơ chế này giúp mô hình nhìn được toàn bộ ngữ cảnh một cách nhanh chóng. Từ đó, mô hình sẽ dễ dàng tìm và ghép các hành vi bất thường bị kéo dài trong nhiều khung hình. Tuy nhiên, nhược điểm của Self-Attention khi xử lý video là rất ngốn RAM. Với các chuỗi dữ liệu dài, độ phức tạp thuật toán lên tới mức $O(N^2)$, rất dễ gây ra tình trạng tràn bộ nhớ (OOM). Để khắc phục vấn đề phần cứng này, mô hình đã chuyển sang sử dụng cơ chế Windowed Self-Attention. Ý tưởng của giải pháp này là thay vì bắt tính toán trên toàn bộ video, mô hình chỉ được phép giới hạn sự chú ý trong một cửa sổ thời gian nhất định gồm một vài khung hình cạnh nhau. Cách thiết kế này không chỉ giảm tải tài nguyên tính toán đáng kể mà còn giúp hệ thống tập trung bắt dính các hành vi cục bộ rất tốt, tạo tiền đề vững chắc trước khi đẩy dữ liệu vào mạng GCN ở các nhánh sau.



Hình 2.2: Cơ chế Scaled Dot-Product Attention (Nguồn: [5])

2.1.5 Thuật toán phân ngưỡng động Otsu

Thuật toán phân ngưỡng Otsu [6] là một phương pháp hiệu quả trong xử lý ảnh, tự động tìm ra giá trị ngưỡng tối ưu để tách dữ liệu thành hai lớp normal và abnormal bằng cách tìm giá trị lớn nhất của phương sai giữa các lớp (inter-class variance). Công thức tính phương sai này được biểu diễn như

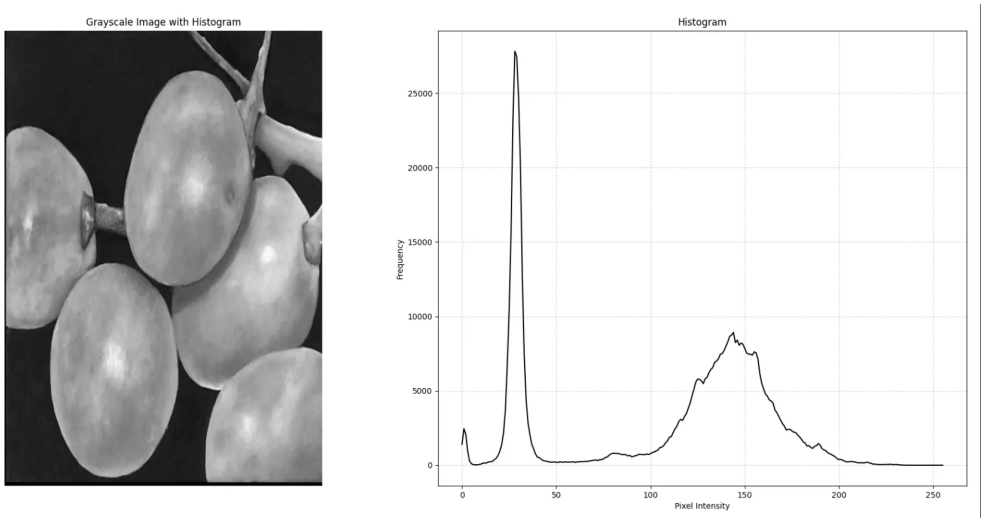
sau:

$$\sigma_B^2(t) = \omega_0(t)\omega_1(t)\left[\mu_0(t) - \mu_1(t)\right]^2 \tag{2.3}$$

Trong đó:

- t là giá trị ngưỡng (threshold) đang xét.
- $\sigma_B^2(t)$ là phương sai giữa hai lớp tại ngưỡng t.
- $\omega_0(t)$ và $\omega_1(t)$ lần lượt là xác suất xuất hiện (tỷ lệ) của lớp 0 và lớp 1.
- $\mu_0(t)$ và $\mu_1(t)$ là giá trị trung bình của dữ liệu trong từng lớp.

Tuy nhiên, về mặt toán học, thuật toán Otsu chỉ hoạt động chính xác nhất dựa trên giả định rằng tập dữ liệu đầu vào có phân phối dạng hai đỉnh (bimodal distribution) rõ rệt. Trong đồ án này, em đã thử nghiệm ứng dụng thuật toán Otsu trên không gian một chiều để phân tách cách phân phối điểm số bất thường của các đoạn segment video. Thay vì dùng để tách background và object trong khung hình như xử lý ảnh truyền thống, Otsu ban đầu được kỳ vọng sẽ giúp mô hình tự động chắt lọc ra các mẫu khung hình bình thường một cách linh hoạt, khắc phục triệt để việc phải gán cứng một con số k rập khuôn gây nhiễu.



Hình 2.3: Minh họa Otsu phân phối hai đỉnh (bimodal) của dữ liệu (Nguồn: [7]
Thuật toán Otsu sẽ tự động tìm kiếm một ngưỡng cắt tối ưu nằm ở khe lõm hai đỉnh này.

2.1.6 Cơ chế chọn mẫu Top-K

Trong bài toán phát hiện bất thường video dưới sự giám sát yếu (WS-VAD), mô hình không được cung cấp nhãn cho từng khung hình mà phải tự dự đoán dựa trên nhãn của cả video (Multiple Instance Learning). Để tính toán hàm mất mát, hệ thống cần trích xuất ra các khung hình đại diện nhất cho video đó. Đây chính là lúc cơ chế lấy mẫu Top-k được sử dụng.

Về mặt toán học, giả sử một video được chia thành N đoạn (segment) nhỏ, sau khi đi qua mạng nơ-ron sẽ thu được tập hợp điểm số bất thường tương ứng là $S = \{s_1, s_2, ..., s_N\}$. Thuật toán Top-k

sẽ thực hiện sắp xếp tập S này theo thứ tự giảm dần:

$$S_{sorted} = \{s_{(1)}, s_{(2)}, ..., s_{(N)}\} \quad \text{với} \quad s_{(1)} \geq s_{(2)} \geq ... \geq s_{(N)} \tag{2.4}$$

Sau đó, hệ thống sẽ trích xuất ra đúng k đoạn có điểm số cao nhất (tức là k đoạn bị nghi ngờ có sự kiện bất thường nhất) để đại diện cho video. Điểm số bất thường ở cấp độ video (S_{video}) thường được tính bằng trung bình cộng của tập Top-k này:

$$S_{video} = \frac{1}{k} \sum_{i=1}^{k} s_{(i)} \tag{2.5}$$

Ưu điểm và Hạn chế: Cơ chế Top-k có ưu điểm là cực kỳ đơn giản, tính toán nhanh và ép mô hình phải tập trung vào những hành vi nổi bật nhất. Tuy nhiên, nhược điểm chí mạng của nó là sự rập khuôn cố định. Giả sử ta thiết lập $k = 10$, nhưng trong thực tế video đó chỉ có đúng 3 đoạn chứa cảnh đánh nhau, thì Top-k vẫn sẽ càn quét và bốc thêm 7 đoạn video bình thường lân cận để gom đủ quân số. Hậu quả là 7 đoạn bình thường này bị mô hình gán nhầm thành "bất thường", sinh ra hiện tượng nhiễu nhãn (Label Noise) làm hỏng các trọng số.

Đây cũng chính là điểm nghẽn buộc đồ án phải tiến hành thử nghiệm so sánh với Otsu. Tuy nhiên, nếu xét ở một góc nhìn học thuật khác, chính sự ràng buộc của việc chỉ bốc đúng k mẫu này, khi được kết hợp với một mạng cơ sở bị khóa chặt (Warm-Start), lại có tiềm năng biến thành một kỹ thuật khai thác mẫu khó (Hard Negative Mining) vô cùng đắc lực nhằm ép mô hình vượt qua giới hạn của chính nó.

2.1.7 Học chuyển giao (Transfer Learning) và kỹ thuật đóng băng trọng số (Weight Freezing)

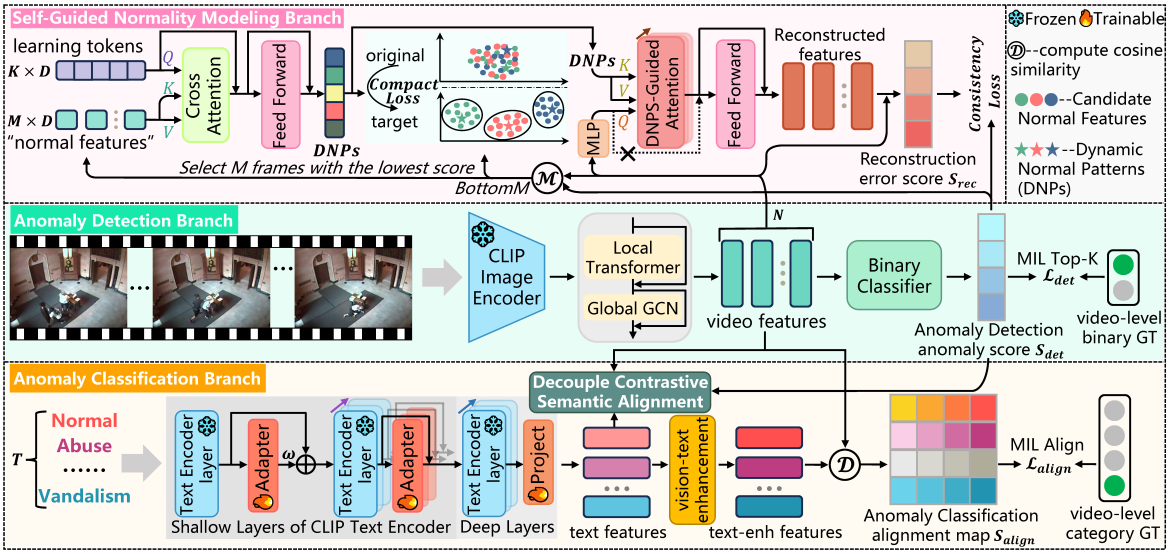
Trong học sâu (Deep Learning), việc huấn luyện một mô hình mạng nơ-ron lớn từ con số không thường đòi hỏi lượng dữ liệu và tài nguyên tính toán khổng lồ. Do đó, phương pháp Học chuyển giao (Transfer Learning) được ứng dụng rộng rãi.

Kỹ thuật này cho phép tái sử dụng các trọng số (weights) đã được huấn luyện trước (pre-trained) trên các tập dữ liệu lớn làm điểm xuất phát cho một bài toán mới. Tuy nhiên, trong quá trình tinh chỉnh các mô hình này, nếu ta mở khóa và cập nhật toàn bộ trọng số cùng một lúc (End-to-End), mô hình rất dễ vấp phải hiện tượng quên ngữ cảnh (Catastrophic Forgetting). Đây là hiện tượng hệ thống vì cố gắng học các mẫu dữ liệu mới (thường chứa nhiều dữ liệu nhiễu) từ đó phá hỏng hoặc quên mất những đặc trưng tổng quát chất lượng cao đã học từ trước, do tác động của các luồng đạo hàm (gradient) nhiễu truyền ngược lại.

Để khắc phục rủi ro này, kỹ thuật đóng băng trọng số (Weight Freezing) kết hợp với chiến lược khởi động ấm (Warm-Start) là một giải pháp thiết yếu. Bằng cách thiết lập tốc độ học (learning rate) của các mạng cơ sở DSANet về 0, ta khóa chặt các tham số này lại, biến chúng thành một lớp bảo về chặn mọi luồng đạo hàm ngược gây nhiễu. Hệ thống lúc này chỉ mở khóa học tập cho một vài mô-đun tinh chỉnh ở phía cuối mạng. Kỹ thuật này không chỉ giúp mô hình hội tụ cực nhanh, tiết kiệm bộ nhớ phần cứng mà còn bảo toàn nguyên vẹn không gian đặc trưng nguyên bản, tạo tiền đề cho các mô-đun RUPA tinh chỉnh phía sau hoạt động ổn định nhất.

2.1.8 Kiến trúc mạng cơ sở DSANet (Baseline)

Mạng cơ sở DSANet (Disentangled Semantic Alignment Network) [8] là một trong những kiến trúc tiên tiến nhất hiện nay trong việc giải quyết bài toán WS-VAD. Khác với các mô hình trước đây chỉ có một luồng xử lý đơn giản, DSANet được thiết kế bao gồm 3 nhánh (branch) phối hợp chặt chẽ với nhau:



Hình 2.4: Sơ đồ kiến trúc 3 nhánh của mạng cơ sở DSANet (Nguồn: [8])

- **Nhánh Phát hiện bất thường (Anomaly Detection Branch):** Đây là xương sống của toàn bộ mô hình. Dữ liệu đầu vào sẽ được trích xuất đặc trưng bằng mô hình CLIP (ViT-B/16), sau đó lần lượt đi qua một bộ Local Transformer để nắm bắt hành động ngắn hạn và mạng đồ thị kép (Global GCN) để liên kết ngữ cảnh dài hạn. Cuối cùng, dữ liệu đi qua lớp phân loại (Classifier) để xuất ra điểm số bất thường cho từng khung hình theo cơ chế Multiple Instance Learning (MIL) kết hợp lấy mẫu Top-k.

- **Nhánh Tự mô hình hóa bình thường (Self-Guided Normality Modeling - SG-NM):** Nhận thấy các mạng MIL truyền thống thường phớt lờ các khung hình bình thường, nhánh SG-NM được sinh ra để tự động đào sâu và học hỏi các khuôn mẫu của video bình thường. Nó tái tạo lại đặc trưng video dựa trên các "nguyên mẫu bình thường động" (Dynamic Normal Patterns), giúp mô hình vạch ra ranh giới rõ ràng hơn giữa sự kiện bình thường và bất thường.

- **Nhánh Phân loại bất thường (Anomaly Classification Branch):** Thay vì chỉ báo động là có sự kiện bất thường, nhánh này có nhiệm vụ phân tích sâu xem đó là loại tội phạm gì (đánh nhau, trộm cắp, hay bạo loạn,...). Bằng cách sử dụng các đoạn văn bản gợi ý (Text Prompt) và cơ chế đối chiếu ngữ nghĩa chéo (Semantic Alignment), nhánh này sẽ ép các vector hình ảnh phải khớp với vector văn bản tương ứng.

Mặc dù sở hữu một thiết kế 3 nhánh rất đồ sộ và thông minh, kiến trúc DSANet gốc lại vấp phải một rào cản chí mạng trong khâu huấn luyện. Việc ép hệ thống phải cập nhật trọng số cho cả 3 nhánh

phức tạp này cùng một lúc (End-to-End) thông qua một hàm loss tổng kết hợp rất dễ sinh ra hiện tượng xung đột đạo hàm (Gradient Interference). Các gradient từ nhánh này cản trở nhánh kia, làm suy giảm nghiêm trọng không gian đặc trưng chất lượng mà bộ trích xuất CLIP đã tạo ra.

Chính việc phân tích sâu vào cấu trúc 3 nhánh này đã giúp đồ án tìm ra khe hở kỹ thuật, từ đó tạo tiền đề cho việc đề xuất đóng băng mạng nền (Warm-Start) và thiết kế thêm mô-đun RUPA ở các chương tiếp theo.

2.2 Các công trình nghiên cứu liên quan

2.2.1 Các phương pháp MIL và mô hình hóa thời gian

Trong các nghiên cứu Phát hiện bất thường video giám sát yếu (WS-VAD), các phương pháp tiếp cận dựa trên Học đa thực thể (MIL) hiện đang là một xu thế mạnh. Người đặt nền móng đầu tiên cho hướng đi này là Sultani và các cộng sự [2] với mạng xếp hạng sâu, trong đó hệ thống sẽ ưu tiên gán điểm cao hơn cho các đoạn video nghi ngờ chứa sự kiện bất thường. Tiếp nối ý tưởng này, Wu và các cộng sự [9] đã đề xuất tận dụng thêm thông tin âm thanh để tăng độ chính xác trong các video bạo lực.

Sau những thành công ban đầu, hàng loạt kiến trúc đã ra đời nhằm cải thiện khả năng nắm bắt chuỗi thời gian của video. Nổi bật có thể kể đến RTFM [10] - tích hợp tích chập thời gian và self-attention để mô hình hóa sự phụ thuộc đa tỉ lệ. Gần đây hơn, kiến trúc MGFN [11] hay phương pháp mạng luồng kép của Le [12] cũng đã tạo ra những tiếng vang lớn khi kết hợp tinh tế giữa việc nhận diện đặc trưng toàn cục (glocal) và cơ chế tập trung (attention). Ngoài ra, phương pháp UMIL [13] cũng là một nỗ lực đáng ghi nhận khi đưa ra chiến lược học biểu diễn ổn định nhằm chống lại sự thiên lệch ngữ cảnh.

2.2.2 Các phương pháp ứng dụng mô hình ngôn ngữ - thị giác

Vài năm trở lại đây, xu hướng nghiên cứu bắt đầu dịch chuyển mạnh mẽ sang việc tận dụng các mô hình nền tảng ngôn ngữ - thị giác (như CLIP). Các nghiên cứu như VadCLIP [14] hay ITC [15] đã khéo léo chèn thêm các gợi ý văn bản (text prompts) vào khung MIL để giúp mô hình nhận diện tốt hơn bằng cách đối chiếu hình ảnh với câu chữ.

Đỉnh cao của hướng đi này tính đến hiện tại là kiến trúc DSANet [8] - cũng chính là mạng cơ sở mà em sử dụng trong đồ án. DSANet giải quyết rất tốt hai bài toán khó là: thiếu khả năng thấu hiểu bối cảnh bình thường và hay nhầm lẫn giữa các loại bất thường có hình ảnh khá tương đồng nhau. Phương pháp này đạt được hiệu năng vượt trội nhờ cơ chế tự mô hình hóa bình thường kết hợp với căn chỉnh ngữ nghĩa chéo.

Mặc dù vậy, khi đào sâu nghiên cứu, em nhận thấy DSANet cũng như các phương pháp MIL trước đây đều chưa giải quyết triệt để một điểm yếu cố hữu: chúng quá phụ thuộc vào việc chọn mẫu theo cơ chế top-k cứng nhắc. Khi xử lý các video có độ dài bất thường biến động (lúc dài lúc ngắn), sự rập khuôn của top-k sẽ gom nhầm các khung hình bình thường vào lớp bất thường, gây ra hiện tượng nhiễu nhãn nặng. Hơn nữa, việc huấn luyện toàn bộ mạng khổng lồ từ đầu đến cuối (End-to-End) rất dễ phá vỡ không gian đặc trưng gốc mà mô hình đã vất vả học được. Chính khoảng trống nghiên cứu này là lý do cốt lõi để em quyết định đề xuất mô-đun RUPA-DSA, đưa thuật toán phân ngưỡng động Otsu vào thử nghiệm so sánh với top-k, đồng thời áp dụng chiến lược huấn luyện tịnh tiến Warm-Start

nhằm bảo toàn tuyệt đối trọng số cho mạng cơ sở DSANet.

2.2.3 Đánh giá tổng quan và so sánh

Để có một cái nhìn trực quan và rõ ràng hơn về sự tiến hóa của các thế hệ kiến trúc, bảng dưới đây tổng hợp so sánh các đặc tính quan trọng giữa những phương pháp phổ biến vừa đề cập và giải pháp RUPA-DSA được đề xuất trong đồ án:

Bảng 2.1: So sánh đặc tính của các công trình nghiên cứu liên quan

Mô hình	**Mạng trích xuất**	**Chiến lược chọn mẫu**	**Hiệu suất ước tính**
Sultani MIL [2]	C3D, I3D	Top-K cố định	Cơ bản
RTFM [10]	I3D	Feature Magnitude	Khá
MGFN [11]	RGB, Flow	Top-K cố định	Tốt
VadCLIP [14]	CLIP	Top-K cố định	Rất tốt
ITC [15]	CLIP	Top-K cố định	Rất tốt
DSANet (Baseline) [8]	CLIP	Top-K cố định	Vượt trội
RUPA-DSA (Đề xuất)	**CLIP**	**Top-K/Otsu (Khảo sát)**	**Tiên tiến (SOTA)**

Qua Bảng tổng hợp trên, có thể thấy rằng sự rập khuôn của tham số Top-K từng được xem là rào cản lớn gây ra hiện tượng nhiễu nhãn dữ liệu cho phần lớn các nghiên cứu WS-VAD. Tuy nhiên, kiến trúc RUPA-DSA được đề xuất trong đồ án này đã tiếp cận theo một hướng hoàn toàn khác. Thông qua các thử nghiệm so sánh chi tiết, đồ án chứng minh rằng việc kết hợp cơ chế Top-K với nền tảng đóng băng trọng số baseline(Warm-Start) sẽ biến chính nhược điểm rập khuôn này thành một kỹ thuật khai thác mẫu khó (Hard Negative Mining) giúp mô hình phát hiện được các bất thường khó thấy. Cải tiến này đóng góp một phần nhỏ nhưng có ý nghĩa vào việc xây dựng các hệ thống giám sát an ninh mạnh mẽ và linh hoạt hơn với dữ liệu thực tế.

Chương 3

Phương pháp đề xuất RUPA-DSA

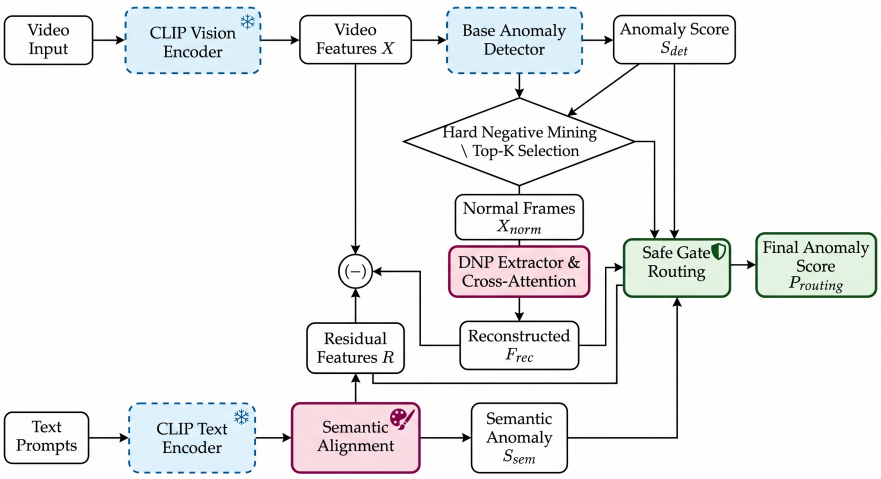
Chương này trình bày chi tiết về kiến trúc hệ thống RUPA-DSA, các khối thành phần cốt lõi và lộ trình thử nghiệm thực tế. Trọng tâm của chương sẽ làm rõ quá trình cải tiến từ phiên bản RUPA-DSA (sử dụng thuật toán Otsu kết hợp huấn luyện End-to-End) sang phiên bản RUPA-DSA dùng Top-K huấn luyện Warm-Start. Cụ thể, đồ án sẽ lý giải tại sao việc lật ngược vấn đề bằng chiến lược đóng băng mạng cơ sở (Warm-Start) kết hợp với kỹ thuật chọn mẫu Top-K lại trở thành chìa khóa giải quyết triệt để bài toán sụt giảm hiệu suất.

3.1 Tổng quan kiến trúc RUPA-DSA

Kiến trúc RUPA-DSA được phát triển dựa trên mạng cơ sở DSANet và tích hợp thêm các mô-đun tinh chỉnh. Tổng quan, luồng dữ liệu của hệ thống đi qua các bước sau:

Đầu tiên, video đầu vào được chia thành T đoạn nhỏ (snippets), mỗi đoạn gồm 16 khung hình. Các đoạn này được đẩy qua bộ mã hóa hình ảnh CLIP (đã đóng băng trọng số) để trích xuất ra ma trận đặc trưng ban đầu $X \in \mathbb{R}^{T\times 512}$. Tiếp theo, dữ liệu đi qua khối mã hóa không gian và thời gian (Spatiotemporal Encoding) được kế thừa từ kiến trúc DSANet. Khối này bao gồm mạng Transformer cửa sổ trượt giúp nắm bắt hành vi cục bộ và mạng Đồ thị tích chập kép (Dual GCN) giúp gom nhóm các sự kiện theo độ tương đồng ngữ nghĩa.

Khác biệt cốt lõi của RUPA-DSA bắt đầu từ thay vì chỉ tin tưởng vào điểm số bất thường của bộ phát hiện cơ sở DSANet, đặc trưng mạng sẽ được phân nhánh đi qua mô-đun **RUPA (Reliability-Aware Unified Prototype Alignment)**. Mô-đun này có nhiệm vụ chắt lọc ra các nguyên mẫu bình thường thuần túy nhất, từ đó đối chiếu ngược lại để phát hiện những khác biệt cực nhỏ do hành vi bất thường. Cuối cùng, kết quả dự đoán từ mạng cơ sở và mô-đun RUPA sẽ được kết hợp thông qua cổng định tuyến an toàn (Safe Gate) nhằm đưa ra dự đoán một cách ổn định nhất.



Hình 3.1: Sơ đồ kiến trúc tổng thể phiên bản RUPA-DSA

Algorithm 1 Luồng xử lý tổng thể của hệ thống RUPA-DSA

Require: Video đầu vào V, Mạng trích xuất đặc trưng CLIP, Mạng cơ sở DSANet đã đóng băng, Mô-đun RUPA, Cổng Safe Gate, Số lượng nguyên mẫu $K = 16$.

Chia video V thành T đoạn nhỏ (snippets).
Trích xuất đặc trưng không gian bằng CLIP: $X \leftarrow \text{CLIP}(V)$
Nắm bắt ngữ cảnh thời gian-không gian qua DSANet:
    $F_{raw}, S_{det} \leftarrow \text{DSANet}(X)$
Chọn lọc tập mẫu khó (Hard Negative Mining):
    $X_{norm} \leftarrow \text{Top-K_Filtering}(S_{det}, X, \text{loại bỏ } K \text{ đoạn cao nhất})$
    Khởi tạo hoặc cập nhật từ điển DNP P từ X_{norm}
Bắt đầu quy trình tinh chỉnh RUPA:
for mỗi đặc trưng đoạn $x_i \in X$ **do**
        Căn chỉnh với nguyên mẫu: $f_{rec,i} \leftarrow \text{Cross-Attention}(x_i, P)$
        Tính đặc trưng phần dư: $r_i \leftarrow x_i - f_{rec,i}$
        Tính điểm bất thường phần dư: $s_{rec,i} \leftarrow \frac{1-\cos(x_i, f_{rec,i})}{2}$
        Căn chỉnh ngữ nghĩa văn bản: $s_{sem,i} \leftarrow 1 - \text{Softmax}(\text{logits_normal}_i)$
Định tuyến an toàn (Safe Gate):
Tính điểm tổng hợp tĩnh: $S_{fixed} \leftarrow \alpha S_{det} + \beta S_{rec} + \gamma S_{sem}$
Tính hệ số cổng mở linh hoạt: $g \leftarrow \text{MLP_Gate}(S_{det}, S_{rec}, S_{sem})$
Dự đoán cuối cùng: $P_{routing} \leftarrow S_{det} + g \cdot (S_{fixed} - S_{det})$
return $P_{routing}$

3.2 Mô-đun RUPA và Cổng định tuyến an toàn (Safe Gate)

3.2.1 Cơ chế tái tạo đặc trưng của RUPA

Mô-đun RUPA là phần mở rộng được thiết kế nhằm tinh chỉnh các điểm số "bất thường" dựa trên nguyên lý phân tích tương phản. Để làm nền tảng cho sự so sánh, hệ thống xây dựng một bộ từ điển bình thường chứa $K = 16$ nguyên mẫu (Dynamic Normal Patterns - DNPs).

Đặc trưng từ các đoạn video được mạng cơ sở đánh giá là "bình thường" sẽ được đẩy qua cơ chế Cross-Attention cùng các khối prototype này. Quá trình này giúp mô hình chắt lọc, tổng hợp và lưu trữ lại những mẫu hình hành vi ổn định nhất của camera. Từ các đặc trưng bình thường đã được làm sạch, mô-đun tiến hành tái tạo phản thực tế và tính toán phần dư theo công thức:

$$R = X - F_{rec} \tag{3.1}$$

Trong đó X là đặc trưng gốc và F_{rec} là đặc trưng được tái tạo. Điểm số bất thường dựa trên sai số tái tạo (S_{rec}) được định lượng thông qua khoảng cách cosine:

$$S_{rec} = \frac{1 - \cos(X, F_{rec})}{2} \tag{3.2}$$

Ngoài ra, để tăng cường độ chắc chắn cho hệ thống, đồ án bổ sung thêm sự căn chỉnh ngữ nghĩa dư (S_{sem}), được tính toán thông qua xác suất của phân lớp bình thường:

$$S_{sem} = 1 - \text{Softmax}(semantic_logits)_{normal} \tag{3.3}$$

Việc kết hợp cả hai thành phần này giúp tận dụng tối đa sức mạnh biểu diễn ngữ nghĩa của CLIP để vạch ra ranh giới rõ ràng hơn giữa sự kiện bình thường và bất thường.

3.2.2 Cổng định tuyến an toàn (Safe Gate)

Mặc dù mô-đun RUPA cung cấp các điểm số bổ sung rất chất lượng, việc cộng gộp trực tiếp chúng vào điểm số gốc rất dễ gây ra hiện tượng nổ đạo hàm (Gradient Explosion) làm mất ổn định hệ thống. Do đó, đồ án thiết kế một cơ chế cổng định tuyến an toàn (Safe Gate) để dung hòa các luồng kết quả một cách nhịp nhàng.

Cụ thể, trước khi đi vào cổng định tuyến, hệ thống sẽ thu thập 3 luồng điểm số dự đoán độc lập:

+ S_{det}: Điểm số dự đoán bất thường gốc do mạng cơ sở DSANet tính toán.

+ S_{rec}: Điểm số dự đoán bất thường do mô-đun RUPA tính toán dựa vào sai số tái tạo đặc trưng hình ảnh.

+ S_{sem}: Điểm số dự đoán bất thường do mô-đun RUPA tính toán dựa vào sự căn chỉnh khớp với văn bản.

Hoạt động của Safe Gate dung hòa 3 điểm số trên được thực hiện qua hai bước:

- **Tính điểm số kết hợp tĩnh:** Một công thức pha trộn được thiết lập nhằm dung hòa các tín

hiệu, với các trọng số α, β, γ được điều chỉnh linh hoạt tùy theo đặc thù của bộ dữ liệu:

$$S_{fixed} = \alpha \cdot S_{det} + \beta \cdot S_{rec} + \gamma \cdot S_{sem} \tag{3.4}$$

Thông qua thực nghiệm trên tập dữ liệu UCF-Crime, hệ thống đạt hiệu suất tối ưu nhất với bộ trọng số $[\alpha, \beta, \gamma] = [0.5, 0.5, 0.0]$. Việc triệt tiêu trọng số ngữ nghĩa ($\gamma = 0$) cho thấy, đối với dữ liệu camera giám sát có độ nhiễu cao, việc tập trung hoàn toàn vào khả năng tái tạo hình ảnh nội tại (S_{rec}) mang lại sự ổn định vượt trội hơn so với việc cố ép khớp với các văn bản mô tả.

- **Cổng linh hoạt (Dynamic Gate):** Một mạng nơ-ron MLP nhỏ được dùng làm van điều tiết. Mạng nhận vector đầu vào chứa các thông tin biến thiên: $[S_{det}, S_{rec}, S_{sem}, |S_{rec} - S_{det}|, |S_{sem} - S_{det}|]$. Mặc dù ở bước tính điểm tĩnh trọng số ngữ nghĩa đã bị triệt tiêu ($\gamma = 0$), tín hiệu S_{sem} và độ lệch của nó vẫn được giữ lại làm đầu vào cho MLP. Nguyên nhân là vì độ lệch ngữ nghĩa ($|S_{sem} - S_{det}|$) cung cấp một manh mối cảnh báo quan trọng về sự mơ hồ của bối cảnh. Dù không đủ độ tin cậy để cộng trực tiếp vào điểm số cuối cùng S_{fixed}, nó vẫn đóng vai trò như một tín hiệu tham khảo giúp mạng MLP đánh giá tình hình và đưa ra quyết định đóng/mở $g \in [0, 1]$ một cách khôn ngoan.

Một kỹ thuật nhỏ nhưng rất quan trọng trong thiết kế cổng này là việc khởi tạo bias của mạng MLP với một giá trị âm. Điều này giúp ép giá trị ban đầu $g \approx 0.01$. Nhờ đó, trong những Epoch đầu tiên, hệ thống gần như chỉ dựa vào bộ phát hiện cơ sở, giúp mô hình không bị "ngợp" trước các tín hiệu nhiễu. Cuối cùng, dự đoán định tuyến tổng thể của toàn hệ thống được tính bằng:

$$P_{routing} = S_{det} + g \cdot (S_{fixed} - S_{det}) \tag{3.5}$$

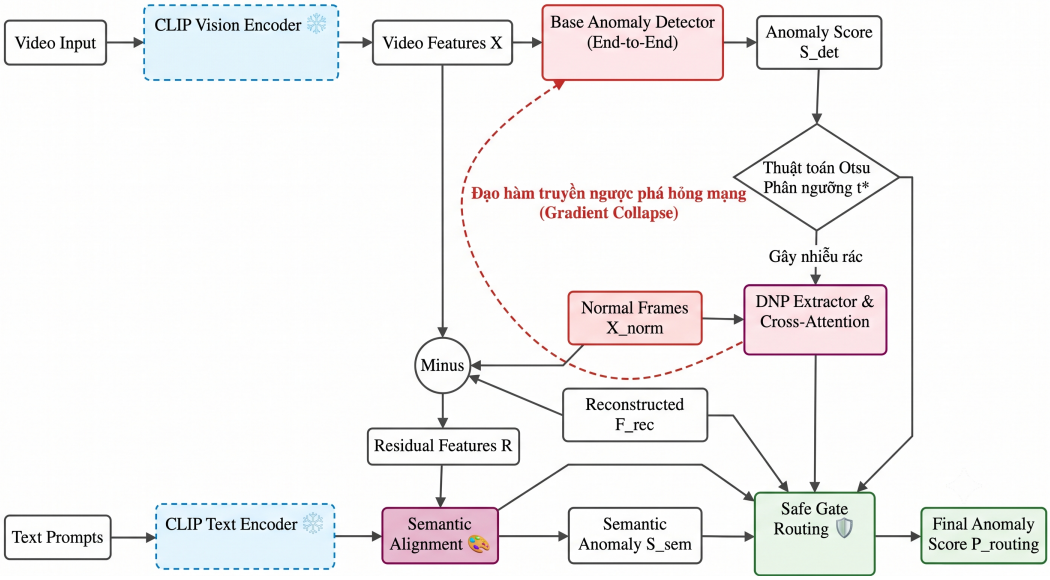
3.3 Phân tích giới hạn của thiết kế Otsu và huấn luyện End-to-End

Trước khi đạt được cấu trúc hoàn chỉnh, hệ thống RUPA-DSA đã trải qua một giai đoạn thiết kế trung gian (phiên bản V2). Ở phiên bản này, đồ án cố gắng tự động hóa hoàn toàn quá trình phân tách đặc trưng bằng thuật toán phân ngưỡng Otsu, kết hợp với chiến lược huấn luyện từ đầu đến cuối (End-to-End).

3.3.1 Lý thuyết cơ chế hoạt động của phiên bản Otsu

Ý tưởng cốt lõi của phiên bản này là tận dụng thuật toán Otsu để tìm ra một ngưỡng tối ưu t^*, nhằm tự động tách phân phối điểm số bất thường S_{det} của mỗi video thành hai cụm rõ rệt. Những đoạn video (snippets) có điểm số dưới ngưỡng t^* sẽ được dán nhãn là "bình thường giả" (pseudo-normal) và được đẩy vào mô-đun RUPA để xây dựng bộ từ điển DNP. Ngược lại, các đoạn có điểm số cao hơn t^* bị loại bỏ khỏi quá trình học DNP nhằm tránh làm nhiễu nguyên mẫu.

Về mặt lý thuyết, việc để thuật toán Otsu tự động tối đa hóa phương sai giữa hai lớp (inter-class variance) được kỳ vọng là một giải pháp hoàn hảo để thay thế cho cơ chế chọn mẫu Top-K. Nguyên nhân vì Top-K luôn ép hệ thống phải trích xuất một số lượng mẫu cố định (ví dụ luôn lấy $K = 16$), gây ra sự cứng nhắc vì mỗi video trong thực tế có thời lượng diễn ra sự kiện bất thường dài ngắn khác nhau. Ngược lại, việc áp dụng Otsu giúp mô hình có khả năng tự động phân tích và linh hoạt thích nghi số lượng mẫu cho từng video độc lập mà không cần gán cứng các tham số rập khuôn. Để minh họa rõ luồng dữ liệu, cấu trúc kiến trúc của RUPA-DSA v2 được trình bày chi tiết trong Hình 3.2.



Hình 3.2: Sơ đồ kiến trúc phiên bản RUPA-DSA sử dụng phân ngưỡng tự động Otsu

3.3.2 Sự sụp đổ đạo hàm (Gradient Collapse) trong thực tế

Tuy nhiên, khi tiến hành huấn luyện thực nghiệm End-to-End, kiến trúc này nhanh chóng lộ những lỗ hổng chí mang về mặt toán học. Vấn đề khởi điểm từ bản chất khởi tạo ngẫu nhiên của các mạng nơ-ron sâu trong những epoch đầu tiên.

Khi mô hình mới bắt đầu huấn luyện, mạng cơ sở DSANet chưa nắm bắt được bất kỳ tri thức nào, dẫn đến điểm số dự đoán S_{det} xuất ra gần như là nhiễu ngẫu nhiên. Khi dải điểm số "rác" này được đưa vào bộ lọc Otsu, thuật toán vẫn máy móc tìm ra một ngưỡng t^* để cắt đôi dải nhiễu này. Hậu quả là mô-đun RUPA bị ép phải học các nguyên mẫu bình thường (DNP) từ một tập dữ liệu hoàn toàn sai lệch.

Thảm họa thực sự xảy ra ở bước lan truyền ngược (Backpropagation). Vì hệ thống huấn luyện End-to-End, các đạo hàm lỗi (error gradients) sinh ra từ một mô-đun RUPA đang bị nhiễu loạn sẽ truyền ngược thẳng về mạng cơ sở DSANet. Quá trình này tạo ra một vòng lặp phá hoại: mạng cơ sở cung cấp điểm số sai $\rightarrow$ Otsu chia tách sai $\rightarrow$ RUPA cũng học sai $\rightarrow$ đạo hàm ngược phá hỏng trọng số của mạng cơ sở. Hiện tượng nhiễu đạo hàm (Gradient Interference) này khiến hệ thống rơi vào trạng thái quên ngữ cảnh, làm hiệu suất của toàn bộ mô hình trượt dốc nặng sau các epoch đầu.

3.4 Chiến lược khắc phục với Warm-Start và cơ chế Top-K

Để giải quyết triệt để thảm họa sụp đổ đạo hàm của phiên bản Otsu, đồ án đã tiến hành đập đi xây lại chiến lược huấn luyện bằng cách kết hợp kỹ thuật Warm-Start và trở lại cơ chế chọn mẫu Top-K. Thay đổi này không chỉ là một bước lùi về mặt thuật toán, mà thực chất là một sự lột xác để biến Top-K thành một cơ chế khai thác mẫu khó (Hard Negative Mining) mạnh mẽ.

3.4.1 Khắc phục nhiễu với chiến lược đóng băng Warm-Start

Thay vì huấn luyện toàn bộ mạng End-to-End từ đầu, hệ thống áp dụng kỹ thuật Warm-Start: Mạng cơ sở DSANet được tải trọng số đã huấn luyện trước (pre-trained) đạt mức khá ổn định, sau đó bị "đóng băng" (freeze) hoàn toàn tham số trong suốt quá trình huấn luyện mô-đun RUPA. Mũi tên đạo hàm truyền ngược bị ngắt bỏ.

Hành động này mang lại hai lợi ích cốt lõi. Thứ nhất, hệ thống lúc này được dẫn đường từ trọng số pre-trained. Điểm số S_{det} xuất ra ở ngay Epoch đầu tiên đã có độ chính xác cao chứ không còn là nhiễu ngẫu nhiên. Thứ hai, mô-đun RUPA được cô lập hoàn toàn, chỉ tập trung vào việc học các nguyên mẫu DNP mà không sợ làm hỏng các tri thức nền tảng mà mạng cơ sở đã vất vả học được.

3.4.2 Sự chuyển mình của Top-K: Từ rập khuôn thành Hard Negative Mining

Khi điểm số đầu ra đã đáng tin cậy nhờ Warm-Start, nhu cầu về một thuật toán phân ngưỡng tự động phức tạp như Otsu trở nên thừa thãi. Lúc này, đồ án quay trở lại sử dụng cơ chế Top-K (với $K = 16$) nhưng ở một cách tiếp cận mới hoàn toàn.

Trong bối cảnh có sự giám sát yếu (Weakly-Supervised), Top-K đóng vai trò như một màng lọc thô bạo nhưng chắc chắn. Hệ thống sẽ lấy 16 đoạn video có điểm số S_{det} cao nhất (chắc chắn là bất thường) vứt sang một bên. Tập hợp các đoạn video còn lại giờ đây được tinh lọc thành một tập "bình thường thuần túy" (Pure Normal Frames). Mô-đun RUPA sẽ sử dụng chính tập dữ liệu sạch này để xây dựng từ điển DNP.

Nhờ vậy, cơ chế Top-K vô tình trở thành một phương pháp **Hard Negative Mining**. Nó giúp vạch ra một ranh giới an toàn tuyệt đối, đảm bảo mô-đun RUPA không bao giờ bị ảnh hưởng xấu bởi các khung hình bất thường lọt lưới. Bằng chứng là thông qua sự kết hợp của cặp đôi Warm-Start và Top-K, hiệu suất của toàn hệ thống không những không sụp đổ mà còn bứt phá vượt trội, vượt xa mạng cơ sở DSANet ban đầu.

3.5 Hệ thống hàm mất mát (Loss Functions)

Để tối ưu hóa toàn diện kiến trúc RUPA-DSA, đặc biệt là trong giai đoạn huấn luyện Warm-Start khi mạng cơ sở đã bị đóng băng, đồ án sử dụng một hệ thống hàm mục tiêu phức hợp. Tổng hàm mất mát $\mathcal{L}_{total}$ được cấu thành từ các thành phần chuyên biệt sau:

- **Hàm mất mát Đa thực thể (MIL Loss - $\mathcal{L}_{MIL}$):**
  Đây là hàm mất mát nền tảng cho bài toán giám sát yếu (Weakly-Supervised). Nó dựa trên nguyên lý lề tối đa (max-margin) để đẩy điểm số bất thường cao nhất của video dương (chứa bất thường) lên cao, và ép điểm số cao nhất của video âm (hoàn toàn bình thường) xuống thấp:

$$\mathcal{L}_{MIL} = \frac{1}{B}\sum_{i=1}^{B} \max(0, 1 - \max(S_{abn}^{(i)}) + \max(S_{nor}^{(i)})) \tag{3.6}$$

  Trong đó, B là kích thước batchsize, S_{abn} và S_{nor} lần lượt là tập hợp điểm số dự đoán của video bất thường và video bình thường.

- **Hàm tối ưu hóa Từ điển DNP ($\mathcal{L}_{Orth}$ và $\mathcal{L}_{Gather}$):**
  Để đảm bảo bộ từ điển nguyên mẫu bình thường (DNP) học được các hành vi phong phú và

không bị trùng lặp, hệ thống sử dụng hàm trực giao (Orthogonal Loss):

$$\mathcal{L}_{Orth} = \left\| PP^T - I \right\|_F^2 \tag{3.7}$$

Trong đó, P là ma trận chứa các nguyên mẫu bình thường (DNP), P^T là ma trận chuyển vị của nó; I là ma trận đơn vị.

Đồng thời, hàm gom cụm (Gather Loss) được áp dụng để ép các đặc trưng bình thường (sau khi đi qua Top-K) phải hội tụ sát về phía các nguyên mẫu P gần nhất, giúp từ điển tốt hơn trong việc tái tạo các hành vi bình thường:

$$\mathcal{L}_{Gather} = \sum_{x \in X_{norm}} \min_k \|x - P_k\|_2^2 \tag{3.8}$$

Trong đó, x là vector đặc trưng của đoạn video thuộc tập bình thường X_{norm}; P_k là nguyên mẫu thứ k trong từ điển DNP.

- **Hàm mất mát tái tạo phần dư ($\mathcal{L}_{Residual}$):**
  Để mô-đun RUPA phản ứng nhạy bén, hàm $\mathcal{L}_{Residual}$ được thiết kế nhằm mục đích ép phần dư (residual) của các khung hình bình thường tiến về 0 (tái tạo hoàn hảo), trong khi phóng to phần dư của các khung hình bất thường (không thể tái tạo):

$$\mathcal{L}_{Residual} = \mathbb{E}[S_{rec}|normal] + \max(0, \eta - \mathbb{E}[S_{rec}|abnormal]) \tag{3.9}$$

  Trong đó:

  - $\mathbb{E}$ là phép toán kỳ vọng (giá trị trung bình).
  - $S_{rec}|normal$ và $S_{rec}|abnormal$ lần lượt là điểm số bất thường (được tính từ sai số tái tạo) của các khung hình bình thường và khung hình bất thường.
  - η là lề an toàn (margin) được thiết lập trước, nhằm đảm bảo sai số tái tạo của khung hình bất thường luôn bị ép phải lớn hơn một ngưỡng nhất định.

- **Hàm mất mát Cổng định tuyến ($\mathcal{L}_{Gate}$ và $\mathcal{L}_{Cons}$):**
  Để ngăn chặn mạng MLP của Safe Gate luôn luôn mở (khiến $g \to 1$ một cách vô tội vạ), đồ án áp dụng một hàm phạt độ thưa (Sparsity Loss) lên trọng số cổng. Ngoài ra, hàm nhất quán ($\mathcal{L}_{Cons}$) được tính toán dựa trên độ lệch giữa điểm hình ảnh và điểm ngữ nghĩa để điều tiết quá trình định tuyến.

Cuối cùng, tổng hàm mất mát toàn cục để cập nhật trọng số cho mô-đun RUPA và Safe Gate được định nghĩa bằng tổng có trọng số của các thành phần trên:

$$\mathcal{L}_{total} = \mathcal{L}_{MIL} + \lambda_1 \mathcal{L}_{Orth} + \lambda_2 \mathcal{L}_{Gather} + \lambda_3 \mathcal{L}_{Residual} + \lambda_4 \mathcal{L}_{Gate} \tag{3.10}$$

Trong đó $\lambda_1, \lambda_2, \lambda_3, \lambda_4$ là các siêu tham số (hyper-parameters) dùng để cân bằng tầm quan trọng của từng nhánh tổn thất trong quá trình lan truyền ngược.

Để làm rõ hơn về mức độ ảnh hưởng của từng thành phần tổn thất, Bảng 3.1 trình bày tóm tắt các giá trị siêu tham số mặc định được thiết lập trong quá trình huấn luyện hệ thống.

Siêu tham số	**Giá trị mặc định**	**Vai trò và Tác động**
λ_1 (Orthogonal Loss)	0.1	Ngăn chặn sự trùng lặp giữa các nguyên mẫu trong từ điển DNP, duy trì sự đa dạng.
λ_2 (Gather Loss)	0.1	Ép các đặc trưng bình thường hội tụ về gần các nguyên mẫu nhất để tăng khả năng biểu diễn.
λ_3 (Residual Loss)	0.1	Phóng to khoảng cách tái tạo của khung hình bất thường và thu hẹp phần dư của khung hình bình thường.
λ_4 (Gate Loss)	0.001	Giữ mạng MLP của cổng định tuyến không bị kích hoạt quá mức (Sparsity) và duy trì sự nhất quán.
η (Margin)	0.2	Lề an toàn đảm bảo khoảng cách sai số tái tạo của bất thường luôn lớn hơn bình thường.

Bảng 3.1: Tóm tắt siêu tham số mặc định của hệ thống hàm mất mát

Chương 4

Kết quả thử nghiệm

4.1 Môi trường thử nghiệm

Trong quá trình thực hiện đồ án, mô hình được tiến hành huấn luyện và kiểm thử trên nền tảng Kaggle Notebook, nhằm tận dụng sức mạnh tính toán của hệ thống GPU kép NVIDIA Tesla T4x2 (với 2x16GB VRAM). Bên cạnh đó, hệ thống được cấu hình với ngôn ngữ lập trình Python phiên bản 3.8 kết hợp cùng thư viện PyTorch phiên bản 1.10 trở lên và nền tảng CUDA, giúp tăng tốc đáng kể quá trình xử lý song song các tác vụ tính toán phức tạp trên tensor. Để có cái nhìn rõ ràng hơn về cách thiết lập, Bảng 4.1 dưới đây trình bày chi tiết các siêu tham số quan trọng đã được áp dụng cho hai bộ dữ liệu UCF-Crime và XD-Violence.

Bảng 4.1: Cấu hình siêu tham số trên hai bộ dữ liệu

Siêu tham số	**UCF-Crime**	**XD-Violence**
Số lớp Transformer (Layers)	2	1
Kích thước cửa sổ (Window)	8	64
Kích thước batch size	64	96
Số epochs	10	10
Learning rate nhánh chính (Main-LR)	0.0	0.0
Learning rate bộ tinh chỉnh (Refiner-LR)	1e-5	1e-5
Số lượng prototypes	16	16
Cấu hình định tuyến Safe Gate $[\alpha, \beta, \gamma]$	0.5 / 0.5 / 0.0	0.5 / 0.3 / 0.2

4.2 Bộ dữ liệu

Để minh chứng cho độ hiệu quả của phương pháp đề xuất, đồ án đã lựa chọn tiến hành thử nghiệm trên hai bộ dữ liệu lớn và phổ biến nhất trong bài toán phát hiện bất thường trong video hiện nay.

4.2.1 Bộ dữ liệu UCF-Crime

Theo các nghiên cứu trước đây [2], UCF-Crime là một tập dữ liệu quy mô lớn bao gồm 1900 video giám sát chưa qua cắt ghép, chứa 13 loại hành vi phạm tội khác nhau ngoài đời thực, và tập kiểm thử chứa 290 video. Đặc điểm nổi bật của bộ dữ liệu này là các video có độ dài rất đa dạng, bao gồm cả những phân cảnh có nhịp độ nhanh và chậm, tạo điều kiện thuận lợi để đánh giá khả năng mô hình hóa sự phụ thuộc thời gian của các mạng học sâu.

4.2.2 Bộ dữ liệu XD-Violence

Mặt khác, bộ dữ liệu XD-Violence [9] lại mang tính chất đa nguồn phức tạp hơn với tổng cộng 4754 video được thu thập từ phim ảnh, trò chơi và camera giám sát, bao gồm 6 loại bạo lực theo định dạng gán nhãn đa lớp (multi-label), trong đó tập test có 800 video. Dữ liệu từ nhiều nguồn khác nhau

không chỉ làm tăng độ khó của bài toán do sự thay đổi về ánh sáng, góc quay và chất lượng hình ảnh, mà còn đặt ra thách thức lớn đối với khả năng khái quát hóa của mô hình.

Bảng 4.2: Thống kê tổng quan hai bộ dữ liệu

Thuộc tính	**UCF-Crime**	**XD-Violence**
Tổng số video	1900	4754
Số loại bất thường	13	6
Loại nhãn	Nhãn đơn (Single-label)	Đa nhãn (Multi-label)
Số video tập test	290	800

4.3 Độ đo đánh giá

Trong bài toán phát hiện bất thường ở cấp độ video, đồ án sử dụng các thang đo chuẩn được cộng đồng nghiên cứu công nhận để đánh giá hiệu suất mô hình, giúp đảm bảo tính khách quan và dễ dàng so sánh chéo với các phương pháp SOTA khác:

- **Diện tích dưới đường cong ROC (AUC - Area Under the ROC Curve):** Được tính toán ở cấp độ khung hình (frame-level), đây là chỉ số chính yếu và phổ biến nhất. Nó đo lường khả năng phân biệt tổng quát của hệ thống giữa khung hình bình thường và bất thường trên mọi ngưỡng (threshold) phân loại.

- **Độ chính xác trung bình (AP - Average Precision):** Hay còn gọi là diện tích dưới đường cong Precision-Recall (PR-AUC). Chỉ số này đặc biệt quan trọng và thường được sử dụng làm thước đo chính cho bộ XD-Violence, nhằm phản ánh chính xác hiệu suất của mô hình khi đối mặt với các tập dữ liệu có độ mất cân bằng nghiêm trọng giữa lớp âm và lớp dương.

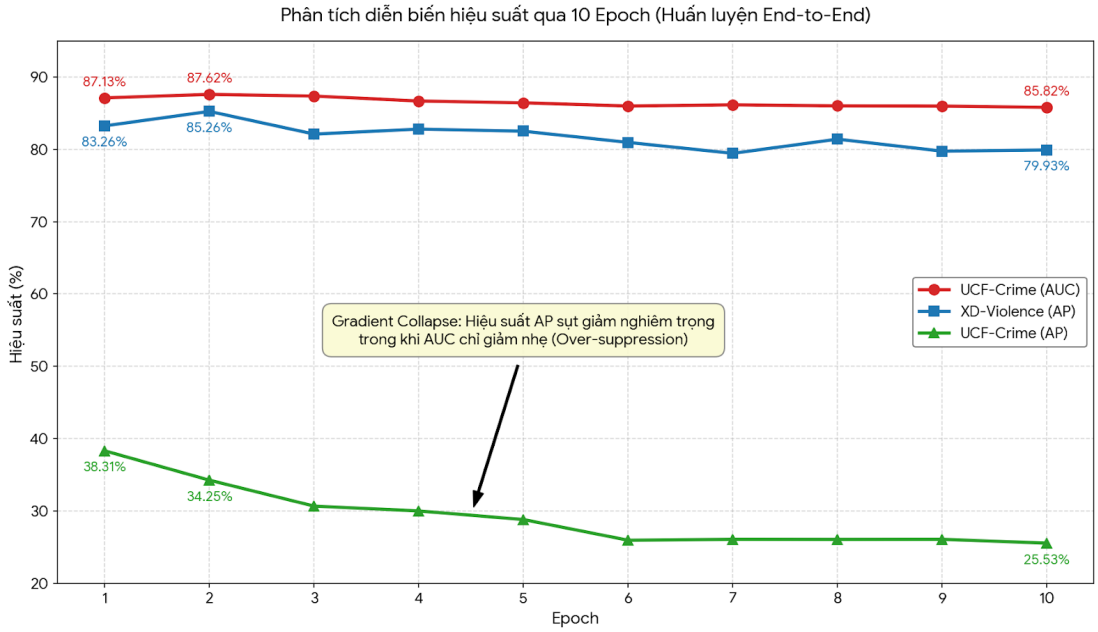
- **Temporal Detection mAP (với IoU từ 0.1 đến 0.5):** Được theo dõi để kiểm tra khả năng định vị chính xác vị trí thời gian của các phân đoạn bất thường. Chỉ số này đánh giá mức độ chồng lấp (Intersection over Union) giữa phân đoạn bất thường mà mô hình dự đoán so với nhãn thời gian thực tế.

4.4 Kết quả trên phiên bản huấn luyện End-to-End

Trong giai đoạn đầu phát triển mô hình, đồ án đã thử nghiệm huấn luyện End-to-End từ đầu, nơi cả bộ trích xuất đặc trưng chính và mô-đun RUPA được tối ưu hóa đồng thời. Tuy nhiên, quá trình này đã bộc lộ những lỗ hổng nghiêm trọng về mặt ổn định toán học (đúng như đã phân tích ở Chương 3).

Đối với tập dữ liệu UCF-Crime, quá trình huấn luyện End-to-End kéo dài 10 Epoch đã bộc lộ rõ điểm yếu cốt lõi của phương pháp phân ngưỡng Otsu thông qua sự phân kỳ của hai thang đo. Về mặt xếp hạng toàn cục, chỉ số AUC vẫn duy trì được sự ổn định tương đối khi đạt đỉnh 87.62% ở Epoch 2 và chỉ suy giảm nhẹ xuống 85.82% tại Epoch 10. Tuy nhiên, mô hình đã bóp nghẹt đặc trưng làm sụp đổ hoàn toàn độ chính xác cục bộ. Cụ thể, chỉ số AP đạt mức rất cao là 38.31% ngay tại Epoch 1, nhưng sau đó nhanh chóng lao dốc xuống 34.25% ở Epoch 2, và tiếp tục chìm sâu không phanh cho đến khi chạm đáy ở mức 25.53% tại Epoch 10.

Tình trạng bất ổn tương tự cũng diễn ra trên bộ dữ liệu XD-Violence. Dù dữ liệu sắc nét hơn giúp mô hình trụ được đến Epoch 2 (đạt đỉnh AP 85.26%), nhưng ngay sau đó, cấu trúc không gian đặc trưng bắt đầu bị phá vỡ khiến AP giảm mạnh xuống 82.12% ở Epoch 3 và duy trì ở mức 79.93% tại Epoch 10. Hình 4.1 minh họa rõ diễn biến hiệu suất này, chứng minh sự thất bại (hiện tượng Gradient Collapse) của chiến lược End-to-End với Otsu.



Hình 4.1: Phân tích hiệu suất qua 10 Epoch minh họa hiện tượng Gradient Collapse khi huấn luyện End-to-End

4.5 Kết quả trên phiên bản huấn luyện Warm-Start

Để giải quyết triệt để tình trạng tuột dốc hiệu suất do sự bất ổn của đạo hàm ở nhánh trích xuất đặc trưng chính, nghiên cứu đã chuyển sang chiến lược huấn luyện Warm-Start. Bằng cách cố định (đóng băng) trọng số của bộ DSANet gốc và chỉ tập trung tối ưu hóa mô-đun RUPA, phương pháp này đã tạo ra phiên bản RUPA-DSA hoàn chỉnh, mang lại sự ổn định trong huấn luyện và bứt phá mạnh mẽ về mặt hiệu suất.

4.5.1 Kết quả trên tập XD-Violence

Kết quả thử nghiệm cho thấy phiên bản RUPA-DSA đã đạt được thành tích cao nhất trên tập XD-Violence, vượt qua nhiều mô hình có tiếng trong cùng lĩnh vực, minh chứng qua Bảng 4.3.

4.5.2 Kết quả trên tập UCF-Crime

Tương tự như vậy, trên bộ dữ liệu UCF-Crime, sự bổ sung của mạng tinh chỉnh RUPA cũng mang lại mức cải thiện đáng chú ý về chỉ số Average Precision so với bản DSANet gốc, đồng thời giữ vững mức AUC ở mức cao. Bảng 4.4 thể hiện chi tiết kết quả này.

Bảng 4.3: So sánh hiệu suất trên bộ dữ liệu XD-Violence

Phương pháp	**Năm**	**AUC (%)**	**AP (%)**
Sultani (MIL) [2]	2018	-	73.20
Wu (HL-Net) [9]	2020	-	78.64
RTFM [10]	2021	-	77.81
MGFN [11]	2023	-	80.11
VadCLIP [14]	2024	-	84.51
DSANet (Baseline) [8]	2026	95.39	86.95
RUPA-DSA (Ours)	**2026**	**95.40**	**87.04**

Bảng 4.4: So sánh hiệu suất trên bộ dữ liệu UCF-Crime

Phương pháp	**Năm**	**AUC (%)**	**AP (%)**
Sultani (MIL) [2]	2018	75.41	-
RTFM [10]	2021	84.30	-
MGFN [11]	2023	86.67	-
VadCLIP [14]	2024	88.02	-
DSANet (Baseline) [8]	2026	89.44	37.85
RUPA-DSA (Ours)	**2026**	**89.55**	**40.21**

4.5.3 So sánh phiên bản huấn luyện End-to-End và Warm-Start

Sự khác biệt lớn nhất giữa phiên bản huấn luyện End-to-End và phiên bản Warm-Start nằm ở quỹ đạo hội tụ.

Trong khi End-to-End trải qua hiện tượng đạt đỉnh sớm (Early Peak) rồi thoái hóa nhanh chóng do nhánh chính bị phá vỡ cấu trúc không gian đặc trưng đã học từ trước, phiên bản Warm-Start lại duy trì được sự ổn định qua từng vòng lặp nhờ việc chỉ tối ưu hóa các tham số phụ trợ của module RUPA. Điều này cho thấy cơ chế đóng băng trọng số kết hợp chiến lược Warm-Start không chỉ bảo toàn được khả năng nhận diện cơ bản mà còn cung cấp đủ không gian cho mô hình tinh chỉnh các dự đoán lỗi.

4.5.4 Phân tích siêu tham số cho Safe Gate

Việc tinh chỉnh bộ trọng số kết hợp tĩnh $[\alpha, \beta, \gamma]$ cho Safe Gate đã cho thấy một đặc tính về sự khác biệt bản chất giữa hai bộ dữ liệu. Thông qua thực nghiệm, tỷ lệ $[0.5, 0.5, 0.0]$ được chứng minh là tối ưu nhất cho UCF-Crime, trong khi tập XD-Violence lại đạt đỉnh tại $[0.5, 0.3, 0.2]$.

Sự triệt tiêu trọng số nhánh ngữ nghĩa ($\gamma = 0$) trên tập UCF-Crime phản ánh đúng bản chất nhiễu loạn của dữ liệu camera an ninh (CCTV). Trong môi trường góc quay hẹp, ánh sáng yếu và chất lượng mờ, việc cố gắng ép khớp đặc trưng hình ảnh với văn bản mô tả (Text Prompts) thông qua CLIP thường mang lại tín hiệu nhiễu nhiều hơn là học tốt hơn. Bằng cách triệt tiêu trọng số này và tin tưởng hoàn toàn vào khả năng nhận diện hình ảnh (S_{det} và S_{rec}), mô hình trở nên ổn định hơn hẳn.

Để minh chứng cho lập luận này, thực nghiệm áp dụng chéo bộ trọng số của XD-Violence $[0.5, 0.3, 0.2]$ lên tập UCF-Crime đã được tiến hành. Kết quả cho thấy, khi ép mô hình chú ý vào nhánh ngữ nghĩa ($\gamma = 0.2$), chỉ số AP lập tức sụt giảm chỉ còn 39.10% (so với mức tối ưu 40.21% của cấu hình gốc). Sự sụt giảm này là minh chứng thực nghiệm rõ nét nhất cho việc đưa thông tin văn bản vào dữ liệu camera mờ nhòe sẽ gây ra tác dụng ngược.

Ngược lại, tập XD-Violence chứa các đoạn phim, trò chơi và video mạng xã hội với chất lượng hình ảnh cao, hành vi bất thường diễn ra vô cùng rõ nét và có âm thanh đi kèm. Nhờ chất lượng đầu vào tốt, nhánh đối sánh ngữ nghĩa ($\gamma = 0.2$) phát huy tối đa tác dụng, giúp mô hình bám sát các khái niệm bạo lực đã được mô tả bằng văn bản, từ đó tăng cường độ tự tin cho các dự đoán bất thường.

Dù vậy, đối với cả hai bộ dữ liệu, độ lệch ngữ nghĩa $|S_{sem} - S_{det}|$ vẫn luôn được giữ lại làm đầu vào cho cổng linh hoạt (Dynamic Gate) nhằm cung cấp thêm manh mối về sự mơ hồ của bối cảnh cho mạng MLP.

4.6 Đánh giá đóng góp của từng module

Để hiểu rõ hơn về mức độ đóng góp của từng module trong hệ thống, đồ án đã thực hiện một chuỗi các thử nghiệm loại bỏ (Ablation Study) nhằm quan sát tác động của chúng đối với hiệu suất cuối cùng trên cả hai tập dữ liệu.

Bảng 4.5: Kết quả Ablation Study trên UCF-Crime và XD-Violence

Cấu hình	**UCF AP (%)**	**UCF AUC (%)**	**XD AP (%)**
DSANet baseline	37.85	89.44	86.95
+ RUPA (End-to-End)	38.31	87.61	85.56
+ RUPA + WS + Otsu + Safe Gate	38.84	89.53	**87.04**
+ RUPA + WS + Top-K + Safe Gate	**40.21**	**89.55**	87.02

Từ Bảng 4.5, có thể thấy rằng dù việc kết hợp các module bao gồm ngưỡng động Otsu và cơ chế cổng an toàn Safe Gate trên Warm-Start có kỳ vọng mang lại hiệu quả cao nhưng việc kết hợp cơ chế lấy mẫu Top-K cùng cổng an toàn Safe Gate trên nền huấn luyện Warm-Start mang lại hiệu quả tốt nhất. Top-K tuy rập khuôn cố định nhưng giúp mô hình khai thác được các mẫu dữ liệu khó (Hard Negative Mining), tạo áp lực cho nhánh RUPA học được các đặc trưng bất thường khó phát hiện và đạt đỉnh.

4.6.1 Phân tích sự chênh lệch hiệu năng giữa các tập dữ liệu

Trong quá trình thử nghiệm cắt bỏ (Ablation Study), đồ án đã ghi nhận một hiện tượng phân phối dữ liệu (Dataset Bias) cực kỳ đáng chú ý: Cơ chế Top-k thể hiện sự vượt trội áp đảo so với Otsu trên tập dữ liệu UCF-Crime, nhưng khoảng cách này lại bị thu hẹp đáng kể và gần như xấp xỉ nhau trên tập XD-Violence.

Sự chênh lệch này xuất phát từ bản chất của từng loại dữ liệu. Đối với tập XD-Violence, các video được thu thập từ phim ảnh và mạng xã hội, nơi các hành vi bạo lực diễn ra vô cùng mãnh liệt, rõ nét và kéo dài. Điều này khiến dải điểm số bất thường phân hóa thành 2 đỉnh (bimodal) rõ rệt. Nhờ đó, thuật toán Otsu dễ dàng tìm được ngưỡng cắt tối ưu, mang lại hiệu năng bám sát nút với Top-k (đều tiệm cận mức AP 87.04%).

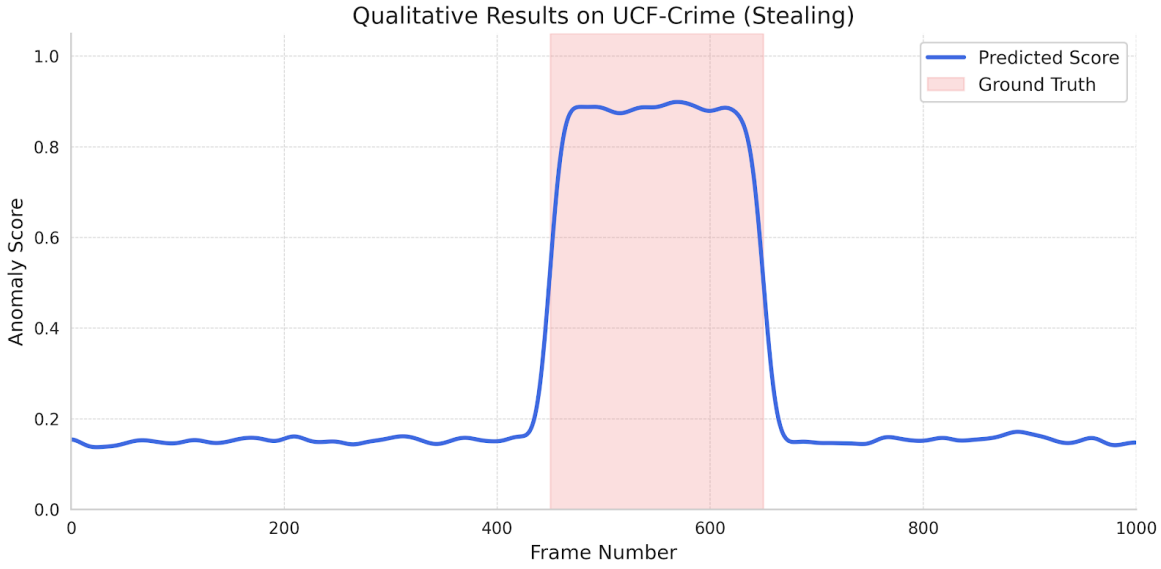
Mặt khác, tập UCF-Crime lại là tập hợp các đoạn băng từ camera an ninh (CCTV) với chất lượng mờ, góc quay chết và các hành vi bất thường (như trộm cắp) diễn ra cực kỳ lén lút, ngắn ngủi. Điểm số giữa khung hình bình thường và bất thường ở tập này bị chồng chéo nghiêm trọng. Trong môi trường nhiễu đặc này, thuật toán Otsu bị mất phương hướng, vô tình thu nạp thêm các khung hình nhiễu vào lớp bất thường làm sai lệch trọng số. Ngược lại, bản tính "cực đoan" của cơ chế Top-k (chỉ bốc đúng k khung hình có điểm tự tin cao nhất) lại vô tình trở thành một bộ lọc nhiễu (noise filter)

hoàn hảo. Nó thẳng tay loại bỏ các khung hình mập mờ, ép nhánh tinh chỉnh RUPA tập trung vào các đặc trưng cốt lõi nhất, từ đó tạo ra sự bứt phá vượt trội về điểm số trên tập UCF-Crime.

4.7 Trực quan hóa kết quả (Qualitative Results)

Bên cạnh các đánh giá định lượng bằng chỉ số AP và AUC, nghiên cứu tiến hành phân tích định tính (Qualitative Analysis) để quan sát hành vi thực tế của mô hình RUPA-DSA khi xử lý chuỗi video thời gian thực.

Hình 4.2 minh họa điểm số bất thường (Anomaly Score) do mô hình dự đoán trên video Stealing021_x264.mp4 thuộc tập UCF-Crime. Vùng được tô màu hồng biểu diễn khoảng thời gian thực tế xảy ra hành vi bất thường (Ground Truth) do con người gán nhãn. Có thể thấy, đường dự đoán của mô hình (màu xanh) duy trì ở mức rất thấp trong các phân cảnh bình thường, nhưng ngay lập tức phản ứng và vọt lên mức điểm tự tin cực kỳ cao (gần như chạm mốc 0.9) ngay khi hành vi trộm cắp bắt đầu xuất hiện trong khung hình. Điều này chứng minh rằng việc kết hợp mạng chính DSANet với bộ tinh chỉnh RUPA mang lại khả năng định vị thời gian (Temporal Localization) cực kỳ nhạy bén, chính xác và bám sát thực tế.



Hình 4.2: Trực quan hóa điểm số bất thường do mô hình dự đoán theo từng khung hình

4.8 Thảo luận

Tổng kết lại chương này, quá trình thử nghiệm đã làm sáng tỏ hiện tượng Early Peak khi áp dụng mô hình theo cơ chế End-to-End thông thường. Điều này hoàn toàn củng cố tính đúng đắn cho cách tiếp cận của RUPA-DSA khi định hướng thiết kế theo dạng một mô-đun bổ trợ linh hoạt. Hơn thế nữa, tính chất dễ dàng tích hợp của mô hình không chỉ giảm thiểu rủi ro làm hỏng mạng trích xuất gốc (backbone) mà còn tạo điều kiện cho việc thử nghiệm trên nhiều cấu trúc mạng khác nhau, đồng thời vẫn phải thừa nhận rằng có những hạn chế nhất định khi hiệu quả phụ thuộc khá nhiều vào chất lượng checkpoint ban đầu của DSANet.

Chương 5

Kết luận và Hướng phát triển

5.1 Kết luận tổng quan

Tổng quát lại, đồ án đã đề xuất và xây dựng hoàn thiện kiến trúc RUPA-DSA (Reliability-Aware Unified Prototype Alignment for Dual Semantic-Aware Network) nhằm giải quyết bài toán phát hiện bất thường trong video. Điểm khác biệt cốt lõi của phương pháp này nằm ở việc thiết kế thêm nhánh mạng RUPA. Thực chất, đây là một cơ chế tinh chỉnh nhận thức độ tin cậy, chuyên đảm nhận việc căn chỉnh các đặc trưng bất thường dựa trên tập nguyên mẫu (prototypes) nhằm bù đắp các sai số từ mạng trích xuất gốc. Để mô-đun này có thể phát huy tối đa hiệu quả trong thực tế, hệ thống đã triển khai đồng thời ba kỹ thuật bổ trợ.

Đầu tiên là chiến lược huấn luyện Warm-Start. Cách tiếp cận này giúp khóa chặt trọng số của mạng nền tảng, đảm bảo không gian đặc trưng cơ bản không bị thoái hóa trong quá trình huấn luyện nhánh mới. Kế đến là khâu lấy mẫu mẫu cứng (Hard Negative Mining) bằng thuật toán Top-K. Thay vì lấy dữ liệu đại trà, cơ chế này chủ động lọc ra các khung hình khó để ép nhánh RUPA phải học cách phân biệt nhiễu. Cuối cùng, cổng an toàn Safe Gate được đặt ở cuối mạng, có chức năng cân đối tỷ lệ cộng gộp điểm số từ RUPA sang kết quả cuối cùng, tránh tình trạng mạng bị lệch chuẩn. Tổng hợp toàn bộ các cơ chế trên, mô hình RUPA-DSA đã ghi nhận mức hiệu suất đột phá, cụ thể là đạt 87.04% AP trên tập XD-Violence và vươn lên mức 40.21% AP đối với bộ dữ liệu UCF-Crime.

5.2 Ưu điểm của phương pháp

Trong bối cảnh hiện tại của bài toán, kiến trúc đề xuất mang lại nhiều ưu điểm học thuật và kỹ thuật đáng ghi nhận:

- **Đặc tính mô-đun hóa linh hoạt:** Kiến trúc cho phép dễ dàng tích hợp bộ tinh chỉnh RUPA vào đằng sau các hệ thống trích xuất (backbone) đã được huấn luyện sẵn mà không làm suy biến cấu trúc tri thức gốc.

- **Kháng nhiễu dữ liệu:** Việc kết hợp cơ chế lấy mẫu Top-K tạo ra một lớp màng lọc tự nhiên, ép mạng nơ-ron phải đối mặt với các mẫu khó để bứt phá giới hạn nhận diện, đặc biệt hiệu quả trên bộ dữ liệu mờ nhòe và mất cân bằng như UCF-Crime.

5.3 Hạn chế của nghiên cứu

Bên cạnh những thành quả đạt được, nghiên cứu cũng tự nhìn nhận một cách khách quan rằng hệ thống vẫn còn tồn tại một số hạn chế nhất định:

- **Sự phụ thuộc trần hiệu suất (Upper Bound):** Do áp dụng đóng băng trọng số (Warm-Start), hiệu năng của mô hình RUPA bị chi phối tuyến tính bởi chất lượng của checkpoint khởi tạo từ DSANet.

- **Sự chênh lệch giữa hai thang đo:** Dù chỉ số định vị cục bộ (AP) tăng vọt, mức độ cải thiện về chỉ số xếp hạng toàn cục (ROC-AUC) vẫn khiêm tốn. Mô hình đang đánh đổi khả năng nhận diện bao quát để lấy độ sắc bén ở cục bộ.

- **Độ nhạy cảm với miền dữ liệu mờ (Domain Gap):** Việc phải triệt tiêu trọng số nhánh ngôn ngữ ($\gamma = 0$) trên tập UCF-Crime cho thấy khả năng liên kết thị giác-ngôn ngữ của mô hình CLIP bị hạn chế mạnh khi đối mặt với dữ liệu camera an ninh chất lượng thấp.

5.4 Khả năng ứng dụng thực tiễn

Với lợi thế về tính gọn nhẹ và khả năng lắp ghép linh hoạt, mô hình RUPA-DSA mang lại tiềm năng ứng dụng to lớn trong các bài toán thực tế:

- **Hệ thống camera an ninh đô thị thông minh (Smart City):** Nhờ khả năng tích hợp linh hoạt, các hệ thống camera đang hoạt động có thể dễ dàng tải thêm module RUPA để tăng cường khả năng phát hiện trộm cắp, ẩu đả mà không cần tốn chi phí huấn luyện lại toàn bộ hệ thống lõi.

- **Giám sát tại các khu vực rủi ro cao:** Có thể triển khai mô hình tại các bệnh viện, trường học hoặc trạm ATM để phát hiện nhanh các hành vi bạo lực (dựa trên tính năng đối sánh văn bản tốt của tập XD-Violence), qua đó tự động kích hoạt cảnh báo sớm cho lực lượng bảo vệ.

5.5 Định hướng phát triển

Từ những kết quả và hạn chế trên, đồ án đề xuất các hướng nghiên cứu mở rộng trong tương lai nhằm nâng cao tính khái quát của hệ thống:

- Chuyển đổi mô hình sang chế độ hoạt động thời gian thực (Real-time Video Anomaly Detection), đáp ứng nhu cầu giám sát an ninh tức thời.

- Áp dụng các backbone trích xuất đa phương thức mạnh mẽ hơn (như VideoMAE hoặc InternVideo2) và kết hợp tín hiệu âm thanh (Multi-modal fusion) để tăng cường manh mối nhận diện sự cố.

- Kết hợp các Mô hình ngôn ngữ lớn (LLM) để tự động sinh ra văn bản giải thích lý do tại sao một hành động cụ thể bị gắn nhãn là bất thường.

- Thử nghiệm chiến lược rã băng từ từ (Gradual Unfreezing) các lớp cuối của backbone trong giai đoạn huấn luyện RUPA nhằm giải quyết giới hạn hiệu suất do Warm-Start gây ra.

5.6 Lời kết

Tóm lại, những hướng đi trong tương lai không chỉ giúp khắc phục triệt để các khuyết điểm còn tồn đọng mà còn mở ra cơ hội đưa hệ thống vào các ứng dụng thực tiễn. Những thành quả bước đầu đạt được từ kiến trúc RUPA-DSA đã minh chứng cho một triết lý thiết kế mạng nơ-ron hiện đại. Thực tế cho thấy, chúng ta không nhất thiết phải đập đi xây lại toàn bộ hệ thống ngay từ đầu. Đôi khi, việc tìm tòi và áp dụng các mô-đun tinh chỉnh nhỏ gọn với tính tích hợp linh hoạt mới chính là giải pháp an toàn, tiết kiệm chi phí và mang lại hiệu quả đột phá nhất.

Tài liệu tham khảo

Tiếng Anh

[1] Li, G. et al. "MemoVAD: Resource-Efficient Video Anomaly Detection via Dynamic Semantic Memory in Edge Computing Scenarios". In: *arXiv preprint* (2026).

[2] Sultani, Waqas, Chen, Chen, and Shah, Mubarak. "Real-world anomaly detection in surveillance videos". In: *Proceedings of the IEEE conference on computer vision and pattern recognition*. 2018, pp. 6479–6488.

[3] Radford, Alec et al. "Learning transferable visual models from natural language supervision". In: *International conference on machine learning*. PMLR. 2021, pp. 8748–8763.

[4] Kipf, Thomas N and Welling, Max. "Semi-supervised classification with graph convolutional networks". In: *International Conference on Learning Representations*. 2017.

[5] Vaswani, Ashish et al. "Attention is all you need". In: *Advances in neural information processing systems*. Vol. 30. 2017.

[6] Otsu, Nobuyuki. "A threshold selection method from gray-level histograms". In: *IEEE transactions on systems, man, and cybernetics* 9.1 (1979), pp. 62–66.

[7] ImageCraft. *Image Segmentation Using Otsu's Thresholding Method*. `https://medium.com/imagecraft/image-segmentation-using-otsus-thresholding-method-f45b1d4bdf22`. Truy cập: 2026.

[8] Yin, Wenti et al. "Learning to Tell Apart: Weakly Supervised Video Anomaly Detection via Disentangled Semantic Alignment". In: *Proceedings of the AAAI Conference on Artificial Intelligence*. 2026.

[9] Wu, Peng et al. "Not only look, but also listen: Learning multimodal violence detection under weak supervision". In: *European conference on computer vision*. Springer. 2020, pp. 322–339.

[10] Tian, Yu et al. "Weakly-supervised video anomaly detection with robust temporal feature magnitude learning". In: *Proceedings of the IEEE/CVF international conference on computer vision*. 2021, pp. 9775–9786.

[11] Chen, Yingxian, Zheng, Nenglun, et al. "Magnitude-contrastive glocal feature network for weakly-supervised video anomaly detection". In: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*. 2023.

[12] Le, Viet T et al. "Attention-based Dual-Stream Network for Weakly-supervised Video Anomaly Detection". In: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*. 2023.

[13] Lv, H. et al. "Unbiased multiple instance learning for weakly supervised video anomaly detection". In: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*. 2023, pp. 8022–8031.

[14] Wu, Peng et al. “Vadclip: Adapting vision-language models for weakly supervised video anomaly detection”. In: *Proceedings of the AAAI Conference on Artificial Intelligence*. Vol. 38. 2024, pp. 6074–6082.

[15] Liu, T., Lam, K.-M., and Bao, B.-K. “Injecting text clues for improving anomalous event detection from weakly labeled videos”. In: *IEEE Transactions on Image Processing* (2024).